

# Fundamentos de la Ciencia de Datos

## *Práctica 1*

Grado en Ingeniería Informática  
Universidad de Alcalá



Pablo García García  
Abel López Martínez  
Álvaro Jesús Martínez Parra  
Raúl Moratilla Núñez

14 de noviembre de 2023

# Índice general

<b>Introducción</b>	<b>3</b>
El lenguaje R . . . . .	3
El lenguaje L <sup>A</sup> T <sub>E</sub> X . . . . .	5
<b>1. Ejercicios guiados</b>	<b>9</b>
1.1. Descripción de los datos . . . . .	9
1.2. Asociación . . . . .	14
1.3. Detección de datos anómalos . . . . .	17
1.3.1. Técnicas estadísticas . . . . .	17
Caja y bigotes . . . . .	18
Media y desviación . . . . .	20
1.3.2. Técnicas de proximidad y densidad . . . . .	21
Algoritmo $k$ -vecinos . . . . .	21
Algoritmo LOF . . . . .	23
<b>2. Ejercicios autónomos</b>	<b>24</b>
2.1. Descripción de los datos . . . . .	24
2.2. Asociación . . . . .	38
2.2.1. Técnicas estadísticas . . . . .	47
Caja y bigotes . . . . .	48
Media y desviación . . . . .	50
2.2.2. Técnicas de proximidad y densidad . . . . .	52
Algoritmo $k$ -vecinos . . . . .	53
Algoritmo LOF . . . . .	57

# Índice de figuras

1.	Logo del lenguaje R . . . . .	3
2.	Esquema de extensiones en L <sup>A</sup> T <sub>E</sub> X . . . . .	6
3.	Creación de orden de usuario . . . . .	7
4.	Modificación de compilación . . . . .	7
5.	Mascota de T <sub>E</sub> X y el CTAN . . . . .	8

# Introducción

## El lenguaje R

El lenguaje R, es un software de uso gratuito comúnmente usado en tareas relacionadas con la estadística, como el análisis o visualización de datos; o en general en la propia Ciencia de Datos. Para ello cuenta con una gran cantidad de paquetes y herramientas que facilitan el trabajo.



Figura 1: Logo del lenguaje R

El CRAN (Comprehensive R Archive Network, <https://cran.r-project.org/>) es un repositorio de recursos en línea que se utiliza para facilitar la distribución, el intercambio y el acceso a una amplia gama de software y paquetes relacionados con el lenguaje de programación R. La página web de CRAN sirve como portal central para acceder a estos recursos y ofrece una variedad de apartados y enlaces útiles para los usuarios de R. A continuación, se proporciona una descripción de los distintos enlaces a los que se puede acceder desde la página principal del CRAN:

- Mirrors: Esta sección permite a los usuarios seleccionar un espejo (mirror) cercano para descargar paquetes y recursos. Los espejos son servidores que almacenan copias de los paquetes y datos de CRAN, lo que ayuda a mejorar la velocidad de descarga y la disponibilidad de los recursos.
- What's new?: En esta sección, los usuarios pueden encontrar información sobre las últimas actualizaciones y novedades en el mundo de R y los paquetes disponibles en CRAN. Esto es útil para estar al tanto de las últimas características y mejoras.
- Search: El enlace “Search” permite a los usuarios buscar paquetes y recursos específicos en el repositorio de CRAN. Además, se puede utilizar la función de búsqueda avanzada del motor de búsqueda de Google.

- CRAN Team: Aquí se puede encontrar información sobre las personas y equipos que trabajan en el mantenimiento y desarrollo de CRAN. Es útil para conocer a las personas detrás de esta valiosa fuente de recursos.
- About R: Esta sección proporciona información sobre el lenguaje de programación R en general. Incluye enlaces a la página de inicio de R y a “The R Journal”, una publicación académica relacionada con R.
- Software: Esta sección ofrece acceso a diversas fuentes y binarios relacionados con R, lo que permite a los usuarios descargar e instalar R en su sistema. También proporciona acceso a paquetes, Task Views y otros recursos.
- Documentation: Aquí los usuarios pueden encontrar documentación esencial relacionada con R. Esto incluye manuales, preguntas frecuentes (FAQs) y contribuciones de la comunidad para ayudar a los usuarios a comprender y utilizar R de manera efectiva.

En R, los paquetes son extensiones de software que contienen funciones, datos y documentación para realizar tareas específicas. Antes de utilizar un paquete, debe ser instalado y posteriormente cargado en la sesión. Algunas de las funciones más útiles para preparar los paquetes de un proyecto son:

#### ■ Paquetes por defecto:

Mediante `getOption("defaultPackages")` se muestra una lista de los paquetes que se cargan por defecto cuando una sesión de R es iniciada. Para cambiar esta lista de archivos, se debe acceder a la ubicación en la que está instalado R, que por defecto es: `C:/Program Files/R/R-4.3.1/library/base/R/Rprofile`, y modificar el archivo como se observa en el Código 1, añadiendo al vector `dp` los paquetes que deseados.

---

```

46 local({dp <- Sys.getenv("R_DEFAULT_PACKAGES")
47     if(identical(dp, "")) ## it fact methods is done first
48         dp <- c("datasets", "utils", "grDevices", "graphics",
49             "stats", "methods", "foreign", "generics", "arules
              ")
50     else if(identical(dp, "NULL")) dp <- character(0)
51     else dp <- strsplit(dp, ",")[[1]]
52     dp <- sub("[:blank:]*([:alnum:]+)", "\\1", dp) # strip
        whitespace
53     options(defaultPackages = dp)
54 })

```

---

Código 1: Modificación en fichero `Rprofile`

#### ■ Instalación de paquetes:

La instalación de paquetes puede ser realizada de tres formas distintas:

##### 1. `install.packages("nombre_del_paquete")`

Esta función recibe por parámetro el nombre del paquete que se desea instalar.

2. `install.packages('ubicacion_del_paquete', rep=NULL)`

A la función también se le puede pasar por parámetro la ubicación del archivo, que recomendablemente debe estar en una carpeta temporal en “c:/”, este archivo se descarga desde:

`https://cran.r-project.org/ > Packages > Table of available packages, sorted by name` > Se elige el paquete y se descarga la versión `r-release` de la sección `Windows binaries`.

3. `utils::menuInstallPkgs()`

Tras la ejecución de este comando aparecerá una ventana en la que se podrá elegir el mirror desde el que se va a descargar el paquete. Tras elegir el mirror (Spain (Madrid) en este caso), aparece otra ventana donde se puede elegir el paquete que se desea instalar. Posteriormente, haciendo doble click, este se instalará automáticamente.

■ **Información de un paquete:**

Cuando se ejecuta `library(help="nombre_del_paquete")`, R muestra información detallada sobre el paquete especificado. Esto incluye una descripción del paquete y una lista de las funciones que contiene, junto con sus descripciones.

■ **Carga de paquetes:**

Si se ejecuta `library(nombre_del_paquete)` con el nombre de un paquete, R cargará el paquete en la sesión para que se puedan utilizar sus funciones y objetos.

■ **Lista de paquetes instalados:**

Al ejecutar `library()` sin argumentos, R mostrará una lista de los paquetes que están actualmente cargados en la sesión de R. Esto permite verificar qué paquetes están disponibles para su uso.

■ **Lista de paquetes cargados:**

Mediante `search()` es posible visualizar un listado completo de los paquetes actualmente cargados en memoria.

Además de todo lo dicho, es recomendable descargar y conocer a conciencia el manual y las viñetas de todos los paquetes que sean usados en los proyectos (disponible en la página web del CRAN).

## El lenguaje $\text{\LaTeX}$

Para la realización de esta práctica, se empleará el concepto de **programación literaria**, que consiste en crear un documento en el que se combine texto con código, de manera que este se pueda explicar y entender de una manera mucho más sencilla. Una forma de realizar esto con código R, es el uso del lenguaje  $\text{\LaTeX}$ , que es un sistema de composición de documentos enfocado al ámbito científico. Es algo similar a un lenguaje de marcas con el que poder definir la estructura de un documento, pero cuenta con la particularidad de que es un lenguaje Turing-completo, por lo que cualquier algoritmo puede ser implementado,

dando una mayor flexibilidad aunque no sea su objetivo principal. Ahora se detallarán los pasos seguidos para su instalación. Para poder trabajar, lo mínimo que será necesario es un compilador de  $\text{\LaTeX}$ , en este caso se ha optado por la distribución  $\text{MiKTeX}$  que lo incluye, ya que se está trabajando en Windows. Además, para una mayor comodidad trabajando con el código, se ha optado por el IDE  $\text{TeXstudio}$ , uno de los más conocidos en la comunidad.

Una vez tratados ambos lenguajes, es necesario entender con qué tipos de extensiones se suele trabajar para ver el proceso de integración con R (sin entrar en profundidad). Estas dependen de cómo se desean almacenar los documentos, o cómo están almacenadas algunas dependencias de los mismos, como por ejemplo, imágenes. Esta tarea se realiza usando un compilador u otro.

Para ello será necesario fijarse en la Figura 2. Por ahora se utilizarán las extensiones con las que se trabajará más a menudo, que serán `.Rnw`, `.tex`, y `.pdf`. La primera de ellas representa los archivos que tienen código  $\text{\LaTeX}$  y R “mezclado”, la segunda aquellos que contienen código  $\text{\LaTeX}$  puro, y la última el documento final.




Figura 2: Esquema de extensiones en  $\text{\LaTeX}$

Existen dos herramientas que permiten trabajar con archivos `.Rnw`, estas son Sweave y Knitr. A pesar de que en la asignatura ha sido propuesta la primera de ellas, se optará por la segunda, pues se encontraron diversos errores al compilar archivos con esta, y al ser más antigua, los documentos finales tenían menos calidad. Knitr ofrece mayor calidad y un mejor formato en el código fuente R mostrado. Para instalarla basta con escribir `install.packages("knitr")` en una consola de R. Sweave viene ya por defecto en el paquete `utils`.

Por último, se explicará cómo se ha agilizado el proceso de trabajo con Knitr y  $\text{TeXStudio}$ . Lo primero será hacer que R cargue por defecto Knitr, para ello se modificará el archivo `Rprofile` en `libray/base/R` dentro de la carpeta de instalación de R, añadiendo `knitr` al resto de paquetes que carga por defecto. Una vez hecho esto, es necesario acceder a la configuración de  $\text{TeXStudio}$ , y aquí a *Compilar*. En la zona *Órdenes de usuario*, se creará una nueva tal y como se ve en la Figura 3, de manera que se indique dónde están los binarios de R, para que pueda crear un fichero `.tex`, y posteriormente invocar al compilador, para

obtener el documento en `.pdf`. `TeXStudio` se encargará de reemplazar el símbolo `%` por el nombre del archivo que se le ordene compilar.

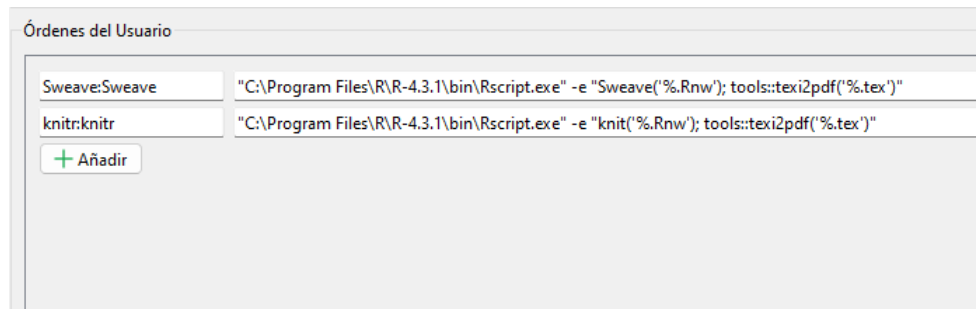


Figura 3: Creación de orden de usuario

Ahora basta modificar el botón verde del IDE para que en vez de invocar al compilador `pdfLATEX`, lleve a cabo la instrucción que se le ha dado. Para ello se accederá al menú de compilación ya visto previamente, y se observará la sección de *Meta-Órdenes*. Se modificará el valor del campo *Compilador por defecto*, escribiendo `txs:///knitr` para que se ejecute la orden previamente creada. Además, es posible hacerlo de manera gráfica como se observa en la Figura 4. Ahora bastará con pulsar el botón verde o `F5` para ver a la izquierda el código de nuestro documento, y a la derecha actualizado, el documento PDF final.

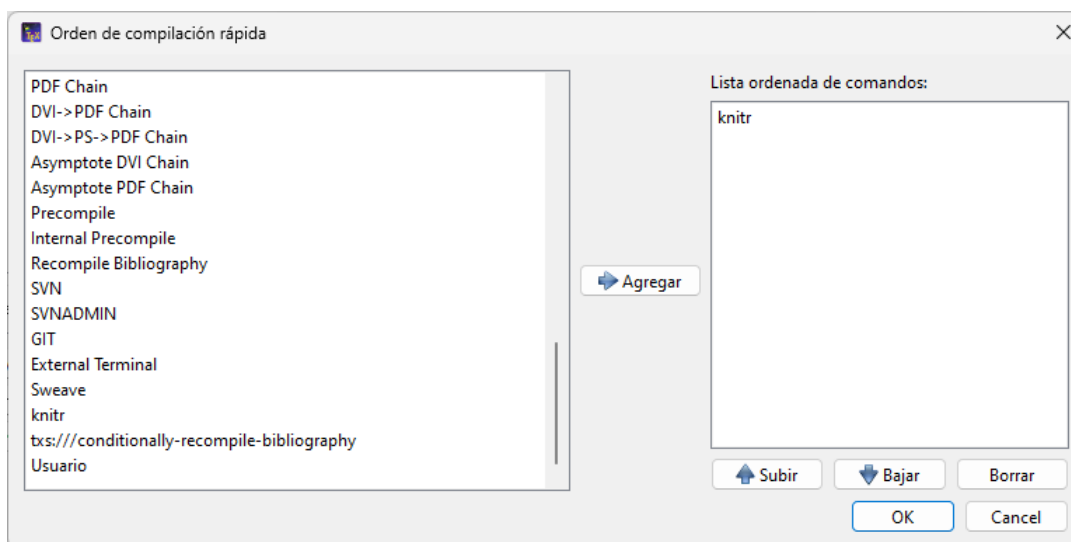


Figura 4: Modificación de compilación

Para llevar un mejor control de versiones del proyecto, y de coordinación entre los miembros del grupo, se usará un repositorio de GitHub. Se ha añadido un archivo `.gitignore` para no cargar en el repositorio los archivos temporales generados durante la compilación. Otra alternativa que se podría haber usado, es el uso de Overleaf (aquí se usaría la extensión `.Rtex` en vez de `.Rnw`), ya que no sería necesaria la instalación de ningún software, y también trabaja con Knitr. Sin embargo, la integración de GitHub en Overleaf es de pago, por lo que



se ha optado por usar la configuración explicada hasta el momento, para poder tener un mejor control de versiones sin coste alguno.

Por otro lado, el profesor explicó cómo abrir un ejemplo de Sweave, cómo pasarlo a un fichero que  $\text{\LaTeX}$  pudiese leer, y cómo compilarlo a PDF. Las instrucciones son las que se verán a continuación, aunque este documento está siendo realizado siguiendo lo explicado previamente.

```
rnwfile <- system.file("Sweave", "example-1.Rnw", package="utils")
Sweave(rnwfile)
tools::texi2pdf("example-1.tex")
```

Por último, mencionar que al igual que R posee su repositorio de paquetes (que como ya se ha visto, contiene más funcionalidades) llamado CRAN,  $\text{\LaTeX}$  que en realidad es “un subconjunto” del lenguaje  $\text{\TeX}$ , también tiene su propio portal llamado CTAN o Comprehensive  $\text{\TeX}$  Archive Network (<https://www.ctan.org/>) de donde se descargan los paquetes y otros materiales para el lenguaje.



Figura 5: Mascota de  $\text{\TeX}$  y el CTAN

# Parte 1

## Ejercicios guiados

En esta primera parte de la práctica, se repetirán los ejercicios explicados y realizados por el profesor en las clases de laboratorio, utilizando los mismos procedimientos vistos y plasmándolos en este documento.

### 1.1. Descripción de los datos

**Ejercicio 1.1.1.** *El primer conjunto de datos, que se empleará para realizar el análisis de descripción de datos, estará formado por datos de una característica cualitativa, nombre, y otra cuantitativa, radio, de los satélites menores de Urano, es decir, aquellos que tienen un radio menor de 50 Km, dichos datos, los primeros cualitativos nominales, y los segundos cuantitativos continuos, son: (Nombre, radio en Km): Cordelia, 13; Ofelia, 16; Bianca, 22; Crésida, 33; Desdémona, 29; Julieta, 42; Rosalinda, 27; Belinda, 34; Luna-1986U10, 20; Calíbano, 30; Luna-999U1, 20; Luna 1999U2, 15.*

Para comenzar con la resolución de este ejercicio, deberán ser escritos los datos en un fichero `.txt`, cumpliendo las siguientes normas:

- Existirá una tabulación entre dato y dato.
- La primera columna numera las filas, y en la primera fila se introduce un espacio y el nombre de las variables.
- Se introducirá un salto de línea en la última fila
- Para los números decimales se utilizarán puntos.
- Al escribir nombres, no se deberán introducir espacios.

Obedeciendo a estas normas, se copian los datos en un fichero llamado `satelites.txt`, y se carga en R de la siguiente manera:

```
s <- read.table("data/satelites.txt")
print(s)
```

```
##          nombre radio
## 1      Cordelia    13
## 2        Ofelia    16
## 3        Bianca    22
## 4      Crésida    33
## 5    Desdémona    29
## 6      Julieta    42
## 7    Rosalinda    27
## 8      Belinda    34
## 9 Luna-1986U10    20
## 10    Calíbano    30
## 11   Luna-999U1    20
## 12  Luna-1999U2    15
```

Ahora en la variable `s` se obtiene un dataframe con los datos de los satélites. Se puede acceder a los dataframes a través de `[fila, columna]`, y también es posible consultar las dimensiones con la función `dim`. Sería de esperar que esta función diera como salida que el dataframe posee 12 filas (los 12 datos), y 2 columnas (`nombre` y `radio`).

```
dim(s)

## [1] 12  2
```

También es posible ordenar el dataframe, en función de una de las magnitudes (columnas), usando la función `order` aplicando recursivamente el concepto de acceder por filas y columnas. Véase un ejemplo, si en `s` se tiene guardado el dataframe, y se desea ordenar por `radio`, la manera de hacerlo sería la siguiente:

```
s_ordered <- s[order(s$radio), ]
print(s_ordered)

##          nombre radio
## 1      Cordelia    13
## 12  Luna-1999U2    15
## 2        Ofelia    16
## 9  Luna-1986U10    20
## 11   Luna-999U1    20
## 3        Bianca    22
## 7    Rosalinda    27
## 5    Desdémona    29
## 10    Calíbano    30
## 4      Crésida    33
## 8      Belinda    34
## 6      Julieta    42
```

Además, es posible introducir nuevos criterios a la ordenación, como por ejemplo, hacerlo en orden descendente. Para esto se utilizará la función `rev`.

```
s_ordered_rev <- s[rev(order(s$radio)), ]
print(s_ordered_rev)

##           nombre radio
## 6      Julieta    42
## 8      Belinda    34
## 4      Crésida    33
## 10     Calíbano    30
## 5     Desdémona    29
## 7     Rosalinda    27
## 3         Bianca    22
## 11    Luna-999U1    20
## 9    Luna-1986U10    20
## 2         Ofelia    16
## 12   Luna-1999U2    15
## 1     Cordelia    13
```

También suele ser útil conocer cuántos elementos tiene una columna. Es posible averiguarlo con la función `length`, véase un ejemplo.

```
length(s$radio)

## [1] 12
```

Otro valor que es posible calcular es el rango. Para ello se utilizan las funciones `max` y `min`. Es necesario tener cuidado con la función `range`, pues esta devuelve los valores máximo y mínimo de la columna.

```
r <- max(s$radio) - min(s$radio)
print(r)

## [1] 29

range(s$radio)

## [1] 13 42
```

Para una mejor lectura, es posible cambiar la forma de obtener la columna de los radios:

```
radio <- s$radio
```

La idea de calcular la diferencia de el máximo y el mínimo a mano parece funcionar, sin embargo, para futuros casos sería más ágil tener codificada una función como la siguiente.

```
rango <- function(radio){max(radio) - min(radio)}
rango(radio)

## [1] 29
```

Sin embargo, al salir de R, la definición de la función se pierde, por lo que para mantenerla es necesario guardarla en un fichero, y posteriormente cargarlo en futuras ejecuciones. Esta acción se realiza de la siguiente manera:

```
dump("rango", file = "fn/rango.R")
source("fn/rango.R")
```

Retomando el estudio de los datos, va a explicarse cómo calcular las diferentes frecuencias. Como en R no existe una función para las frecuencias relativas, se definirá y guardará una propia.

```
fabs_radio <- table(radio)
fabsacum_radio <- cumsum(fabs_radio)
frecrel <- function(r){table(r)/length(r)}
dump("frecrel", file = "fn/frecrel.R")

print(fabs_radio)

## radio
## 13 15 16 20 22 27 29 30 33 34 42
##  1  1  1  2  1  1  1  1  1  1  1

print(fabsacum_radio)

## 13 15 16 20 22 27 29 30 33 34 42
##  1  2  3  5  6  7  8  9 10 11 12

print(frecrel(radio))

## r
##      13      15      16      20      22      27      29
## 0.08333333 0.08333333 0.08333333 0.16666667 0.08333333 0.08333333 0.08333333
##      30      33      34      42
## 0.08333333 0.08333333 0.08333333 0.08333333
```

Otro valor que es posible calcular es la media aritmética de los datos, para ello se cuenta con la función `mean`.

```
mr <- mean(radio)
print(mr)

## [1] 25.08333
```

Tras la media, se calculará la desviación típica, para ello se cuenta con la función `sd`.

```
sdr <- sd(radius)
print(sdr)

## [1] 8.857029
```

Sin embargo, el resultado obtenido no es el esperado. Esto se debe a que esta función realiza el siguiente cálculo

$$s = \sqrt{\frac{\sum_{i=0}^n (x_i - \bar{x})^2}{n - 1}}$$

que es más utilizado en inferencia estadística, porque hace que se parezca más a una campana de Gauss (menos sesgo), mientras que la fórmula vista en clase utiliza un factor de  $n$  en vez de  $n - 1$  en el denominador (dentro de la raíz). Para solucionar el problema, el profesor lo corrigió de la siguiente manera:

```
sdr2 <- sqrt((sdr^2)*(length(radius)-1)/length(radius))
print(sdr2)

## [1] 8.47996
```

En realidad lo que se está realizando es el siguiente “ajuste”:

$$s' = \sqrt{s^2 \cdot \frac{n - 1}{n}}$$

Una vez se ha visto cómo se calcula la desviación típica, se va a explicar cómo calcular la varianza. Dado que esta es el cuadrado de la desviación típica, bastaría con elevar al cuadrado si no fuera por el “fallo” de  $n - 1$  visto previamente. En este caso, el profesor lo arregló para el caso particular de la siguiente manera:

```
varr <- var(radius)
varr <- 11/12 * varr
print(varr)

## [1] 71.90972
```

Otro de los valores que se ha enseñado cómo calcular, es la mediana. Para este caso existe la función `median`.

```
medianr <- median(radius)
print(medianr)

## [1] 24.5
```

En último lugar, el profesor enseñó cómo calcular cuantiles, y para ello mostró la función `quantile`, pero se mencionó que se obtienen resultados diferentes a los esperados debido a la forma que tiene de calcularlos, y se deberá programar. Aquí se muestra un ejemplo de cómo se calcularía el primer cuartil.

```
cuar1 <- quantile(radio, 0.25)
print(cuar1)

## 25%
## 19
```

## 1.2. Asociación

**Ejercicio 1.2.1.** *El segundo conjunto de datos, que se empleará para realizar el análisis de asociación, estará formado por las siguientes 6 cestas de la compra: {Pan, Agua, Leche, Naranjas}, {Pan, Agua, Café, Leche}, {Pan, Agua, Leche}, {Pan, Café, Leche}, {Pan, Agua}, {Leche}.*

Lo primero explicado por el profesor fue la preparación de los datos proporcionados para que `arules` fuese capaz de tratar con ellos. Para ello se introduce una matriz de ceros y unos mediante el paquete `Matrix`, que indique en cada suceso, qué elementos contiene. Así, cada fila representará un suceso de la muestra y cada columna corresponderá con un suceso elemental; de tal forma que si ese suceso elemental se encuentra en un suceso de la muestra, su posición en la matriz será un 1, y en caso contrario será un 0. La matriz es la siguiente:

$$\begin{pmatrix} 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

Además, deberán ser indicadas las dimensiones de esta matriz ( $6 \times 5$ ), que se están introduciendo los datos por filas (`byrow=TRUE`), y con `dimnames` se asociarán los nombres a las filas y las columnas. El código es el siguiente.

```
muestra <- Matrix(c(1, 1, 0, 1, 1,
1, 1, 1, 1, 0,
1, 1, 0, 1, 0,
1, 0, 1, 1, 0,
1, 1, 0, 0, 0,
0, 0, 0, 1, 0), 6, 5, byrow = TRUE, dimnames = list(
c("suceso1", "suceso2", "suceso3", "suceso4", "suceso5", "suceso6"),
c("Pan", "Agua", "Café", "Leche", "Naranjas")), sparse=TRUE)
muestra
```

```
## 6 x 5 sparse Matrix of class "dgCMatrix"
##           Pan Agua Café Leche Naranjas
## suceso1   1    1    .    1    1
## suceso2   1    1    1    1    .
## suceso3   1    1    .    1    .
## suceso4   1    .    1    1    .
## suceso5   1    1    .    .    .
## suceso6   .    .    .    1    .
```

A continuación, se ha enseñado cómo mostrar la matriz con puntos y barras, en vez de con unos y ceros. Se consigue con la función `as` y el parámetro `nsparseMatrix`.

```
muestrangCMatrix <- as(muestra, "nsparseMatrix")
muestrangCMatrix

## 6 x 5 sparse Matrix of class "ngCMatrix"
##           Pan Agua Café Leche Naranjas
## suceso1   |    |    .    |    |
## suceso2   |    |    |    |    .
## suceso3   |    |    .    |    .
## suceso4   |    .    |    |    .
## suceso5   |    |    .    .    .
## suceso6   .    .    .    |    .
```

Sin embargo, para el algoritmo, es necesario pasar por parámetro justo la transpuesta de la matriz con la que se trabaja, por ello se utiliza la función `t`.

```
transpmuestrangCMatrix <- t(muestrangCMatrix)
transpmuestrangCMatrix

## 5 x 6 sparse Matrix of class "ngCMatrix"
##           suceso1 suceso2 suceso3 suceso4 suceso5 suceso6
## Pan           |    |    |    |    |    .
## Agua          |    |    |    .    |    .
## Café          .    |    .    |    .    .
## Leche         |    |    |    |    .    |
## Naranjas      |    .    .    .    .    .
```

Es posible consultar información acerca de la matriz usando la función `as` con el parámetro `transactions`. Además, con `summary` se puede ver un resumen de algunos parámetros básicos de los datos que contiene la matriz.

```
transacciones = as(transpmuestrangCMatrix, "transactions")
transacciones
```



```
## transactions in sparse format with
## 6 transactions (rows) and
## 5 items (columns)

summary(transacciones)

## transactions as itemMatrix in sparse format with
## 6 rows (elements/itemsets/transactions) and
## 5 columns (items) and a density of 0.5666667
##
## most frequent items:
##      Pan      Leche      Agua      Café Naranjas  (Other)
##      5         5         4         2         1         0
##
## element (itemset/transaction) length distribution:
## sizes
## 1 2 3 4
## 1 1 2 2
##
##      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.
##      1.000  2.250   3.000   2.833   3.750   4.000
##
## includes extended item information - examples:
## labels
## 1 Pan
## 2 Agua
## 3 Café
##
## includes extended transaction information - examples:
## itemsetID
## 1 suceso1
## 2 suceso2
## 3 suceso3
```

Finalmente, se ejecuta el algoritmo apriori llamando a la función `apriori` del paquete `arules`. Se define en este caso el soporte con un valor del 50 %, y la confianza con 80 %.

```
asociaciones = apriori(transacciones, parameter =
list(support = 0.5, confidence = 0.8))

## Apriori
##
## Parameter specification:
## confidence minval smax arem aval originalSupport maxtime support minlen
##      0.8      0.1      1 none FALSE                TRUE      5      0.5      1
```

```

## maxlen target ext
##      10 rules TRUE
##
## Algorithmic control:
## filter tree heap memopt load sort verbose
##    0.1 TRUE TRUE FALSE TRUE    2    TRUE
##
## Absolute minimum support count: 3
##
## set item appearances ...[0 item(s)] done [0.00s].
## set transactions ...[5 item(s), 6 transaction(s)] done [0.00s].
## sorting and recoding items ... [3 item(s)] done [0.00s].
## creating transaction tree ... done [0.00s].
## checking subsets of size 1 2 3 done [0.00s].
## writing ... [7 rule(s)] done [0.00s].
## creating S4 object ... done [0.00s].

```

Es posible visualizar el resultado del algoritmo con la función `inspect`.

```
inspect(asociaciones)
```

	lhs	rhs	support	confidence	coverage	lift	count
## [1]	{}	=> {Leche}	0.8333333	0.8333333	1.0000000	1.00	5
## [2]	{}	=> {Pan}	0.8333333	0.8333333	1.0000000	1.00	5
## [3]	{Agua}	=> {Pan}	0.6666667	1.0000000	0.6666667	1.20	4
## [4]	{Pan}	=> {Agua}	0.6666667	0.8000000	0.8333333	1.20	4
## [5]	{Leche}	=> {Pan}	0.6666667	0.8000000	0.8333333	0.96	4
## [6]	{Pan}	=> {Leche}	0.6666667	0.8000000	0.8333333	0.96	4
## [7]	{Agua, Leche}	=> {Pan}	0.5000000	1.0000000	0.5000000	1.20	3

En esta imagen se observa el resultado del algoritmo. Se deben ignorar las dos primeras filas, pues no tiene sentido alguno que  $\emptyset \rightarrow \{\text{Leche}\}$ , o que  $\emptyset \rightarrow \{\text{Pan}\}$ , aparecen por cómo el autor del paquete codificó el algoritmo. En el resto de casos  $A \rightarrow B$ , indica cómo de probable es comprar  $B$  cuando se compra  $A$  (en función del soporte y la confianza provistas).

## 1.3. Detección de datos anómalos

### 1.3.1. Técnicas estadísticas

**Ejercicio 1.3.1.** *El tercer conjunto de datos, que se empleará para realizar el análisis de detección de datos anómalos utilizando técnicas con base estadística, estará formado por los siguientes 7 valores de resistencia y densidad para diferentes tipos de hormigón {Resistencia, Densidad}: {3, 2; 3.5, 12; 4.7, 4.1; 5.2, 4.9; 7.1, 6.1; 6.2, 5.2; 14, 5.3}. Aplicar las medidas de ordenación a la resistencia y las de dispersión a la densidad.*

## Caja y bigotes

Es una herramienta gráfica utilizada en estadística para representar la distribución de un conjunto de datos y detectar sucesos anómalos o outliers. Para realizar el cálculo de los outliers en clase, se introducen los datos en una matriz mediante `matrix`, posteriormente se debe transponer y se convierte a un `dataframe`. Para esta primera técnica se va a utilizar la primera columna (`resistencia`).

```
muestra=t(matrix(c(3,2,3.5,12,4.7,4.1,5.2,4.9,7.1,6.1,6.2,5.2,14,5.3),
2,7,dimnames=list(c("resistencia","densidad"))))

(muestra=data.frame(muestra))

##      resistencia densidad
## 1           3.0        2.0
## 2           3.5       12.0
## 3           4.7        4.1
## 4           5.2        4.9
## 5           7.1        6.1
## 6           6.2        5.2
## 7          14.0        5.3
```

Una forma de obtener los outliers es mediante la función `boxplot`, pasándole la columna de los datos, el grado de outlier (`range`) o distancia a la que el suceso se considera outlier, y por último `plot=FALSE`, que se usa para no mostrar el gráfico como tal y solo sacar la información por el terminal.

```
(boxplot(muestra$r, range=1.5, plot=FALSE))

## $stats
##      [,1]
## [1,] 3.00
## [2,] 4.10
## [3,] 5.20
## [4,] 6.65
## [5,] 7.10
##
## $n
## [1] 7
##
## $conf
##      [,1]
## [1,] 3.677181
## [2,] 6.722819
##
```

```
## $out
## [1] 14
##
## $group
## [1] 1
##
## $names
## [1] "1"
```

Como es posible visualizar en `$out`, se obtiene que el suceso outlier es el 14, que como se vió en el ejercicio de la clase de teoría es correcto. Sin embargo, si al fijarse en `$conf`, se pueden ver los límites del intervalo, y estos no coinciden con los vistos en clase. Esto es debido a que, al igual que ocurría al usar la función `sd` para el cálculo de la desviación, R utiliza un factor de  $n - 1$  en vez de  $n$ , por lo que no son los valores exactos.

Tras codificar el algoritmo caja y bigotes, se va a realizar la identificación de outliers mediante el cálculo de los cuartiles. Además, se han calculado los límites del intervalo mediante la siguiente ecuación.

$$(Q_1 - d(Q_3 - Q_1), Q_3 + d(Q_3 - Q_1)) \quad (1.1)$$

```
(cuar1r=quantile(muestra$r, 0.25))

## 25%
## 4.1

(cuar3r=quantile(muestra$r, 0.75))

## 75%
## 6.65

(int=c(cuar1r-1.5*(cuar3r-cuar1r), cuar3r+1.5*(cuar3r-cuar1r)))

##      25%      75%
## 0.275 10.475
```

Por último, se iteran los elementos de la muestra y se comprueba para cada uno si es menor que el límite inferior del intervalo o si es mayor que el límite superior.

```
for (i in 1:length(muestra$r)) {
  if (muestra$r[i] < int[1] || muestra$r[i] > int[2]) {
    print("el suceso")
    print(i)
    print("es un suceso anómalo o outlier")
  }
}
```

```

    }
}

## [1] "el suceso"
## [1] 7
## [1] "es un suceso anómalo o outlier"

```

En este ejercicio, al igual que se vio en clase, el suceso outlier es el que está en la posición número 7, es decir el elemento 14.

## Media y desviación

Otra forma de buscar sucesos outliers utilizando técnicas con base estadística es mediante el uso de la media y la desviación típica. Para mostrar esta técnica, se va a utilizar la otra columna del dataframe (**densidad**). A través el uso de las funciones **mean** y **sd** se obtienen ambos valores, que son unidos en los límites del intervalo mediante la siguiente ecuación.

$$(\bar{x}_a - d \cdot s_a, \bar{x}_a + d \cdot s_a) \quad (1.2)$$

```

(media = mean(muestra$d))

## [1] 5.657143

(desv = sd(muestra$d))

## [1] 3.085913

(int=c(media-2*desv, media+2*desv))

## [1] -0.5146825 11.8289682

```

Se observa que los valores inferior y superior del intervalo no son iguales que en el ejercicio realizado en clase, esto se debe a que, como ya se vio, la desviación típica se calcula con un factor de  $n - 1$  en vez de  $n$ , por lo que arreglando el cálculo de la desviación quedaría así.

```

(desv = sqrt(sd(muestra$d)^2 *
(length(muestra$d)-1) / length(muestra$d)))

## [1] 2.857

(int=c(media-2*desv, media+2*desv))

## [1] -0.05685714 11.37114285

```

```

for (i in 1:length(muestra$d)) {
  if (muestra$d[i] < int[1] || muestra$d[i] > int[2]) {
    print("el suceso")
    print(i)
    print("es un suceso anómalo o outlier")
  }
}

## [1] "el suceso"
## [1] 2
## [1] "es un suceso anómalo o outlier"

```

Como resultado, se obtienen los valores del intervalo correctos y se puede ver que el suceso anómalo es el que se encuentra en la posición 2, es decir el elemento 12.

### 1.3.2. Técnicas de proximidad y densidad

**Ejercicio 1.3.2.** *El cuarto conjunto de datos, que se empleará para realizar el análisis de detección de datos anómalos utilizando técnicas basadas en la proximidad y en la densidad, estará formado por las siguientes 5 calificaciones de estudiantes: 1. {4, 4}; 2. {4, 3}; 3. {5, 5}; 4. {1, 1}; 5. {5, 4} donde las características de las calificaciones son: (Teoría, Laboratorio).*

#### Algoritmo $k$ -vecinos

El algoritmo  $k$ -vecinos utilizado para identificar outliers basado en distancias, consiste en calcular la distancia de un punto a sus  $k$  vecinos más cercanos y considerar los puntos con distancias mayores a un cierto valor (grado de outlier) como anómalos.

En clase se añadieron todos los datos de la nueva muestra a una matriz, que luego fue transpuesta para tener los datos dispuestos como requería el cálculo de distancias. Se calcularon las distancias euclídeas mediante la función `dist` y se guardó en una matriz de  $5 \times 5$ , para poder visualizar la distancia de cada punto hacia el resto. El cálculo de esta distancia se realiza de la siguiente manera.

$$\text{dist}(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

```

muestra=matrix(c(4,4,4,3,5,5,1,1,5,4),2,5)
muestra=t(muestra)
distancias=as.matrix(dist(muestra))
(distancias=matrix(distancias,5,5))

```

```
##          [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] 0.000000 1.000000 1.414214 4.242641 1.000000
## [2,] 1.000000 0.000000 2.236068 3.605551 1.414214
## [3,] 1.414214 2.236068 0.000000 5.656854 1.000000
## [4,] 4.242641 3.605551 5.656854 0.000000 5.000000
## [5,] 1.000000 1.414214 1.000000 5.000000 0.000000
```

Mediante el siguiente bucle, se itera cada punto y ordena de menor a mayor las distancias hacia los demás puntos.

```
for (i in 1:5) {
  distancias[,i] = sort(distancias[,i])
}

(distanciasordenadas=distancias)

##          [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] 0.000000 0.000000 0.000000 0.000000 0.000000
## [2,] 1.000000 1.000000 1.000000 3.605551 1.000000
## [3,] 1.000000 1.414214 1.414214 4.242641 1.000000
## [4,] 1.414214 2.236068 2.236068 5.000000 1.414214
## [5,] 4.242641 3.605551 5.656854 5.656854 5.000000
```

Por último, se itera cada punto de la matriz de distancias ordenadas y se comprueba si el elemento  $k$ -ésimo está a una distancia mayor de 2,5 (elegido arbitrariamente), donde el punto se consideraría outlier.

En el código se puede ver que se elige el elemento 4 en lugar del 3 que era la  $k$  elegida para resolverlo, esto se debe a que la primera fila de valores, son las distancias desde cada punto hacia sí mismo, es decir, siempre 0, por lo que quedan descartados en el conteo de los  $k$  elementos.

```
for (i in 1:5) {
  if (distanciasordenadas[4,i] > 2.5) {
    print(i)
    print("es un suceso anómalo o outlier")
  }
}

## [1] 4
## [1] "es un suceso anómalo o outlier"
```

Se obtiene como salida que el punto 4 es un suceso anómalo o outlier, al igual que ocurría en el ejercicio resuelto en teoría.

## Algoritmo LOF

Como último ejercicio realizado en clase, se ha empleado el algoritmo LOF o LOCAL OUTLIER FACTOR para identificar outliers basado en distancias, que evalúa la densidad local de puntos en relación con sus vecinos, identificando valores anómalos en regiones menos densas que el entorno circundante.

Se obtiene una matriz de distancias haciendo uso de la función `dist`, pero en este caso se pasa como parámetro el método deseado para calcular la distancia (`method="manhattan"`), en este caso *Manhattan*, que se ejecuta de la siguiente forma.

$$\text{dist}(x_i, x_j) = |x_{i_1} - x_{j_1}| + |x_{i_2} - x_{j_2}|$$

```
(distanciasM=as.matrix(dist(muestra, method="manhattan")))  
  
##    1 2 3 4 5  
## 1 0 1 2 6 1  
## 2 1 0 3 5 2  
## 3 2 3 0 8 1  
## 4 6 5 8 0 7  
## 5 1 2 1 7 0
```

Para finalizar, el profesor nombró algunos paquetes que realizaban una implementación no simplificada del algoritmo, estos son `RLOf`, `DDoutlier` y `DMwR`, pero en el segundo ejercicio autónomo de detección de datos anómalos, se implementará un código propio, que realice las simplificaciones oportunas.



## Parte 2

# Ejercicios autónomos

### 2.1. Descripción de los datos

**Ejercicio 2.1.1.** *El primer conjunto de datos, que se empleará para realizar el análisis de descripción de datos, estará formado por datos de una característica cuantitativa, distancia, desde el domicilio de cada estudiantes hasta la Universidad, dichos datos, cuantitativos continuos, son: 16.5, 34.8, 20.7, 6.2, 4.4, 3.4, 24, 24, 32, 30, 33, 27, 15, 9.4, 2.1, 34, 24, 12, 4.4, 28, 31.4, 21.6, 3.1, 4.5, 5.1, 4, 3.2, 25, 4.5, 20, 34, 12, 12, 12, 12, 5, 19, 30, 5.5, 38, 25, 3.7, 9, 30, 13, 30, 30, 26, 30, 30, 1, 26, 22, 10, 9.7, 11, 24.1, 33, 17.2, 27, 24, 27, 21, 28, 30, 4, 46, 29, 3.7, 2.7, 8.1, 19, 16.*

Para comenzar, se han introducido todos los datos en un fichero CSV. Para realizar este fichero se ha abierto un fichero Excel y se han ido introduciendo los datos en la primera columna. Cabe destacar que la primera fila no corresponde a ningún valor ya que se ha puesto **Distancia** (km) para mantener la estructura con respecto al ejercicio guiado. Una vez han sido introducidos todos los datos, se guarda el fichero con extensión `.csv`. Para leer este fichero dentro de R se hace uso de la función `read.csv`, perteneciente al paquete por defecto `utils`. Esta función en realidad es un uso diferente de la función `read.table` orientado a la lectura de ficheros CSV. Esta función lee el archivo en formato tabla y a partir de él crea un dataframe haciendo corresponder las filas y las columnas de la tabla.

La función empleada ha sido `read.csv` primeramente porque es un fichero CSV y además porque está delimitado por comas (en caso de haber estado delimitado por punto y coma se debería haber usado `read.csv2`). Se observa en la siguiente línea de código cómo se ha creado un archivo `distancia_universitarios.csv` siguiendo la estructura mencionada previamente. Con este fichero creado basta con llamar a la función `read.csv` pasando como parámetro el fichero. Si el archivo estuviera en otro directorio, habría que pasar por parámetro la ruta donde se encuentra dicho archivo.

```
fichero = read.csv("data/distancia_universitarios.csv")
fichero

##      Distancia
```

## 1	16.5
## 2	34.8
## 3	20.7
## 4	6.2
## 5	4.4
## 6	3.4
## 7	24.0
## 8	24.0
## 9	32.0
## 10	30.0
## 11	33.0
## 12	27.0
## 13	15.0
## 14	9.4
## 15	2.1
## 16	34.0
## 17	24.0
## 18	12.0
## 19	4.4
## 20	28.0
## 21	31.4
## 22	21.6
## 23	3.1
## 24	4.5
## 25	5.1
## 26	4.0
## 27	3.2
## 28	25.0
## 29	4.5
## 30	20.0
## 31	34.0
## 32	12.0
## 33	12.0
## 34	12.0
## 35	12.0
## 36	5.0
## 37	19.0
## 38	30.0
## 39	5.5
## 40	38.0
## 41	25.0
## 42	3.7
## 43	9.0
## 44	30.0

```
## 45      13.0
## 46      30.0
## 47      30.0
## 48      26.0
## 49      30.0
## 50      30.0
## 51       1.0
## 52      26.0
## 53      22.0
## 54      10.0
## 55       9.7
## 56      11.0
## 57      24.1
## 58      33.0
## 59      17.2
## 60      27.0
## 61      24.0
## 62      27.0
## 63      21.0
## 64      28.0
## 65      30.0
## 66       4.0
## 67      46.0
## 68      29.0
## 69       3.7
## 70       2.7
## 71       8.1
## 72      19.0
## 73      16.0
```

Como se puede observar, se ha leído correctamente el fichero, creando el dataframe con los datos leídos. Al ser un CSV delimitado por comas, hay que tener cuidado con los números decimales y separar estos por un punto, ya que si se separa por comas, se tomará para cada dato la parte entera y la parte decimal del mismo como dos datos en vez de uno.

Como se va a trabajar todo el rato con la columna `Distancia` del dataframe, para no tener que acceder repetidamente a esta, se puede definir en una variable nueva llamada `distancias`, de tal forma que no se tenga que estar pasando `fichero$Distancia` repetidamente.

```
distancias = fichero$Distancia
```

Para conocer la longitud de `distancias`, se ha decidido elaborar una función propia, la cual devolverá un escalar con el número de elementos que contenga la lista (`distancias` en este caso).

```
len = function(list) {  
  count = 0  
  for (element in list) {  
    count = count + 1  
  }  
  count  
}
```

La función `len` se basa en un contador el cual se inicializa a 0 y, por medio de un bucle, iterar todos los elementos de la lista y aumentar en 1 cada vez que haya un nuevo elemento. Por último, se devolverá el contador. Esta función será fundamental en otras funciones tal y como se verá más adelante. Llamando a la función se visualiza el número de distancias que se tienen:

```
(longitud = len(distancias))  
  
## [1] 73
```

Se observa que se tienen 73 elementos, es decir, 73 distancias. La próxima utilidad que se necesita es la ordenación de la lista de distancias. Para ello se ha elaborado una función que ordenará la lista en sentido ascendente o descendente utilizando el método de la burbuja.

El método de la burbuja consiste en ir evaluando por pares todos los elementos de una lista, de tal forma que se vayan reposicionando según el sentido en el que se esté ordenando. En caso de ir ordenando en sentido ascendente, el mayor elemento de la lista se irá reposicionando hasta llegar a la derecha del todo. En caso de hacerlo en sentido descendente, el elemento que quedará a la derecha del todo será el menor. Conforme se vaya avanzando, se tendrá por cada iteración un elemento más colocado a la derecha del todo, y así sucesivamente hasta que todos los elementos queden ordenados. Esto se consigue en un tiempo  $\mathcal{O}(n^2)$ . La función que realiza este método de ordenación es la siguiente:

```
bubble = function(list, asc = TRUE) {  
  n = len(list)  
  direccion = ifelse(asc, 1, -1)  
  for (i in 2:n) {  
    for (j in 1:(n-1)) {  
      if (list[j] * direccion > list[j+1] * direccion) {  
        temp = list[j]  
        list[j] = list[j+1]  
        list[j+1] = temp  
      }  
    }  
  }  
  list  
}
```

A esta función se le deberá pasar la lista que se quiere ordenar y **TRUE** o **FALSE** para indicar en el sentido que se quiere ordenar. En caso de ser **TRUE** se ordenará de manera ascendente, y en caso de **FALSE** se ordenará de forma descendente. Por defecto, si solo se pasa como parámetro la lista, se ordenará de forma ascendente.

Además, el algoritmo de ordenación de la burbuja hace uso de la variable **direccion**, la cual adquiere los valores de 1 (en sentido ascendente) y  $-1$  (en sentido descendente). Esto se consigue con la función **ifelse** del paquete **base**, a la cual se le pasa un valor booleano y dos valores. En función del valor booleano, si este es **TRUE** se coge el primer valor y si es **FALSE** el segundo. El valor escogido es asignado a la variable **direccion**. Esta cambiará o no el signo de los elementos de la lista que se está ordenando. En los números positivos, cuanto mayor sea el valor mayor será este, y en los negativos al revés. Si se ordena una lista de números negativos quedará a la derecha del todo el menor valor al ser este el número mayor. Esto se puede generalizar al sentido de ordenación de la lista.

Se comprueba el funcionamiento de esta función haciendo la prueba con la lista de distancias:

```
(distancias_asc = bubble(distancias))

## [1] 1.0 2.1 2.7 3.1 3.2 3.4 3.7 3.7 4.0 4.0 4.4 4.4 4.5 4.5 5.0
## [16] 5.1 5.5 6.2 8.1 9.0 9.4 9.7 10.0 11.0 12.0 12.0 12.0 12.0 12.0 13.0
## [31] 15.0 16.0 16.5 17.2 19.0 19.0 20.0 20.7 21.0 21.6 22.0 24.0 24.0 24.0 24.0
## [46] 24.1 25.0 25.0 26.0 26.0 27.0 27.0 27.0 28.0 28.0 29.0 30.0 30.0 30.0 30.0
## [61] 30.0 30.0 30.0 30.0 31.4 32.0 33.0 33.0 34.0 34.0 34.8 38.0 46.0

(distancias_desc = bubble(distancias, FALSE))

## [1] 46.0 38.0 34.8 34.0 34.0 33.0 33.0 32.0 31.4 30.0 30.0 30.0 30.0 30.0 30.0
## [16] 30.0 30.0 29.0 28.0 28.0 27.0 27.0 27.0 26.0 26.0 25.0 25.0 24.1 24.0 24.0
## [31] 24.0 24.0 22.0 21.6 21.0 20.7 20.0 19.0 19.0 17.2 16.5 16.0 15.0 13.0 12.0
## [46] 12.0 12.0 12.0 12.0 11.0 10.0 9.7 9.4 9.0 8.1 6.2 5.5 5.1 5.0 4.5
## [61] 4.5 4.4 4.4 4.0 4.0 3.7 3.7 3.4 3.2 3.1 2.7 2.1 1.0
```

Con la lista ordenada, se puede saber de forma muy sencilla el rango. Previamente, en los ejercicios guiados, se tenía que llamar a las funciones **max** y **min**. Con la lista ordenada, se pueden acceder a estos valores, ya que estarán en el primer y último índice en función del sentido en el que se haya ordenado la lista. Es por ello que resulta muy fácil crear una función **rango**.

```
rank = function(list) {
  ordered_list = bubble(list)
  ordered_list[len(ordered_list)] - ordered_list[1]
}
```

Primeramente, se ha ordenado la lista en orden ascendente, de tal forma que el valor máximo se encontrará en el último índice y el valor mínimo en el primero. Para calcular el

rango se resta al elemento del último índice, el del primero. Se comprueba la función y se observa que se obtiene un rango de 45.

```
(rango_dist = rank(distancias))
```

```
## [1] 45
```

Ahora se realizará el cálculo de las frecuencias absoluta y relativa y sus respectivas acumuladas. Para ello, nuevamente se crea una función para cada una. La primera que se va a realizar y en la que se basará el resto, será la frecuencia absoluta. El código de la función es el siguiente:

```
absolute_freq = function(list) {
  ordered_list = bubble(list)
  n = len(ordered_list)
  elements = vector()
  frequencies = vector()
  i = 1
  while (i <= n) {
    actual_element = ordered_list[i]
    elements = append(elements, actual_element)
    actual_freq = 0
    j = i
    while(j <= n & actual_element == ordered_list[j]) {
      actual_freq = actual_freq + 1
      j = j+1
    }
    frequencies = append(frequencies, actual_freq)
    i = j
  }
  rbind(elements, frequencies)
}
```

El algoritmo consiste en iterar toda la lista. Se tienen dos listas auxiliares, una de elementos y otra de las frecuencias de esos elementos. Con la lista ordenada, cada vez que se encuentra un elemento distinto del anterior, se apunta en la lista de elementos, y mientras se continua iterando la lista, se van apuntando en un contador auxiliar las veces que va apareciendo ese elemento. Nótese que el elemento va a aparecer contiguo y no va a volver a aparecer en el resto de la lista, ya que previamente ha sido ordenada. De esta forma, se encuentra un elemento, se cuentan las veces contiguas que aparece y cuando aparece otro elemento, se apuntan las frecuencias del anterior y se inicia el mismo procedimiento con el siguiente elemento. Una vez se completa la iteración de la lista, se devuelve con `rbind` una matriz que es el resultado de la matriz previa (la lista de todos los elementos de la muestra) y una lista de elementos con sus correspondientes frecuencias a modo de fila concatenada.

Para esta función se han utilizado las funciones de **append** (paquete **base**) que devuelve un vector con la lista que se pasa como parámetro y el elemento que se introduce como parámetro concatenado a la derecha del mismo, y la función **rbind** (paquete **base**), que devuelva una matriz con los vectores que se pasan como parámetros a modo de fila. Se comprueban las frecuencias absolutas:

```
(frecuencia_abs = absolute_freq(distancias))

##           [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
## elements      1  2.1  2.7  3.1  3.2  3.4  3.7   4  4.4  4.5     5  5.1
## frequencies    1  1.0  1.0  1.0  1.0  1.0  2.0   2  2.0  2.0     1  1.0
##           [,13] [,14] [,15] [,16] [,17] [,18] [,19] [,20] [,21] [,22] [,23]
## elements      5.5  6.2  8.1     9  9.4  9.7   10   11   12   13   15
## frequencies    1.0  1.0  1.0     1  1.0  1.0    1    1    5    1    1
##           [,24] [,25] [,26] [,27] [,28] [,29] [,30] [,31] [,32] [,33] [,34]
## elements      16 16.5 17.2    19   20  20.7   21  21.6   22   24  24.1
## frequencies    1  1.0  1.0     2    1  1.0    1  1.0    1    4   1.0
##           [,35] [,36] [,37] [,38] [,39] [,40] [,41] [,42] [,43] [,44] [,45]
## elements      25  26   27   28   29   30  31.4   32   33   34  34.8
## frequencies    2    2    3    2    1    8   1.0    1    2    2   1.0
##           [,46] [,47]
## elements      38   46
## frequencies    1    1
```

Una vez realizadas las frecuencias absolutas se van a realizar las frecuencias relativas. La frecuencia relativa no es más que la frecuencia absoluta de un elemento dividido entre el total de elementos. Para realizar este cálculo se disponen de todas las herramientas, ya que se tiene la función **len**, que dice cuántos elementos hay, y la función de frecuencias absolutas que se acaba de realizar. Se puede codificar otra función que devuelva una matriz (con **rbind** al igual que se ha visto en el ejercicio anterior) con los elementos distintos de la lista y su frecuencia absoluta dividida entre la longitud de la misma. Siguiendo esta idea, el código de la función es el siguiente.

```
relative_freq = function(list) {
  f_abs = absolute_freq(list)
  elements = f_abs[1,]
  abs_fvalues = f_abs[2,]
  rbind(elements, abs_fvalues/len(list))
}
```

Se comprueban las frecuencias relativas de la lista.

```
(frecuencia_rel = relative_freq(distancias))

##           [,1]      [,2]      [,3]      [,4]      [,5]      [,6]
## elements 1.00000000 2.10000000 2.70000000 3.10000000 3.20000000 3.40000000
```

```
##          0.01369863 0.01369863 0.01369863 0.01369863 0.01369863 0.01369863
##          [,7]      [,8]      [,9]      [,10]     [,11]     [,12]
## elements 3.70000000 4.00000000 4.40000000 4.50000000 5.00000000 5.10000000
##          0.02739726 0.02739726 0.02739726 0.02739726 0.01369863 0.01369863
##          [,13]     [,14]     [,15]     [,16]     [,17]     [,18]
## elements 5.50000000 6.20000000 8.10000000 9.00000000 9.40000000 9.70000000
##          0.01369863 0.01369863 0.01369863 0.01369863 0.01369863 0.01369863
##          [,19]     [,20]     [,21]     [,22]     [,23]
## elements 10.00000000 11.00000000 12.00000000 13.00000000 15.00000000
##          0.01369863 0.01369863 0.06849315 0.01369863 0.01369863
##          [,24]     [,25]     [,26]     [,27]     [,28]
## elements 16.00000000 16.50000000 17.20000000 19.00000000 20.00000000
##          0.01369863 0.01369863 0.01369863 0.02739726 0.01369863
##          [,29]     [,30]     [,31]     [,32]     [,33]
## elements 20.70000000 21.00000000 21.60000000 22.00000000 24.00000000
##          0.01369863 0.01369863 0.01369863 0.01369863 0.05479452
##          [,34]     [,35]     [,36]     [,37]     [,38]
## elements 24.10000000 25.00000000 26.00000000 27.00000000 28.00000000
##          0.01369863 0.02739726 0.02739726 0.04109589 0.02739726
##          [,39]     [,40]     [,41]     [,42]     [,43]     [,44]
## elements 29.00000000 30.000000 31.40000000 32.00000000 33.00000000 34.00000000
##          0.01369863 0.109589 0.01369863 0.01369863 0.02739726 0.02739726
##          [,45]     [,46]     [,47]
## elements 34.80000000 38.00000000 46.00000000
##          0.01369863 0.01369863 0.01369863
```

Por último, se elaborarán dos funciones para las frecuencias acumuladas absoluta y relativa. Con todas las frecuencias de cada elemento y la lista ordenada se puede iterar la lista de frecuencias e ir sumando para cada elemento la suma de las frecuencias de los elementos menores o iguales al elemento del que se está calculando. Dependiendo de qué frecuencia acumulada se esté calculando se tendrá que trabajar con la función de frecuencias absolutas (`absolute_freq`) o con la de frecuencias relativas (`relative_freq`). Se irá iterando cada elemento y se irá creando un nuevo vector con la frecuencia acumulada. Los códigos de las funciones que realizan la frecuencia absoluta acumulada y la frecuencia relativa acumulada son respectivamente los siguientes:

```
acum_absolute_freq = function(list) {
  f_abs = absolute_freq(list)
  elements = f_abs[,1]
  abs_fvalues = f_abs[,2]
  acum_abs_fvalues = vector()
  acum = 0
  for (i in 1:len(elements)) {
    acum = acum + abs_fvalues[i]
    acum_abs_fvalues = append(acum_abs_fvalues, acum)
  }
}
```



```

    rbind(elements, acum_abs_fvalues)
}

acum_relative_freq = function(list) {
  f_rel = relative_freq(list)
  elements = f_rel[1,]
  rel_fvalues = f_rel[2,]
  acum_rel_fvalues = vector()
  acum = 0
  for (i in 1:len(elements)) {
    acum = acum + rel_fvalues[i]
    acum_rel_fvalues = append(acum_rel_fvalues, acum)
  }
  rbind(elements, acum_rel_fvalues)
}

```

Como se puede observar es el mismo código solo que en uno se trabajan con las frecuencias absolutas y en el otro con las relativas. Se comprueba su funcionamiento:

```

(frecuencia_abs_acum = acum_absolute_freq(distancias))

##           [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
## elements      1 2.1 2.7 3.1 3.2 3.4 3.7 4 4.4 4.5 5 5.1
## acum_abs_fvalues 1 2.0 3.0 4.0 5.0 6.0 8.0 10 12.0 14.0 15 16.0
##           [,13] [,14] [,15] [,16] [,17] [,18] [,19] [,20] [,21] [,22]
## elements      5.5 6.2 8.1 9 9.4 9.7 10 11 12 13
## acum_abs_fvalues 17.0 18.0 19.0 20 21.0 22.0 23 24 29 30
##           [,23] [,24] [,25] [,26] [,27] [,28] [,29] [,30] [,31] [,32]
## elements      15 16 16.5 17.2 19 20 20.7 21 21.6 22
## acum_abs_fvalues 31 32 33.0 34.0 36 37 38.0 39 40.0 41
##           [,33] [,34] [,35] [,36] [,37] [,38] [,39] [,40] [,41] [,42]
## elements      24 24.1 25 26 27 28 29 30 31.4 32
## acum_abs_fvalues 45 46.0 48 50 53 55 56 64 65.0 66
##           [,43] [,44] [,45] [,46] [,47]
## elements      33 34 34.8 38 46
## acum_abs_fvalues 68 70 71.0 72 73

(frecuencia_rel_acum = acum_relative_freq(distancias))

##           [,1] [,2] [,3] [,4] [,5]
## elements      1.00000000 2.10000000 2.70000000 3.10000000 3.20000000
## acum_rel_fvalues 0.01369863 0.02739726 0.04109589 0.05479452 0.06849315
##           [,6] [,7] [,8] [,9] [,10] [,11]
## elements      3.40000000 3.700000 4.0000000 4.4000000 4.5000000 5.0000000
## acum_rel_fvalues 0.08219178 0.109589 0.1369863 0.1643836 0.1917808 0.2054795
##           [,12] [,13] [,14] [,15] [,16] [,17]

```

```

## elements      5.1000000 5.5000000 6.2000000 8.100000 9.0000000 9.4000000
## acum_rel_fvalues 0.2191781 0.2328767 0.2465753 0.260274 0.2739726 0.2876712
##              [,18]      [,19]      [,20]      [,21]      [,22]
## elements      9.7000000 10.0000000 11.0000000 12.0000000 13.0000000
## acum_rel_fvalues 0.3013699 0.3150685 0.3287671 0.3972603 0.4109589
##              [,23]      [,24]      [,25]      [,26]      [,27]
## elements      15.0000000 16.0000000 16.5000000 17.2000000 19.0000000
## acum_rel_fvalues 0.4246575 0.4383562 0.4520548 0.4657534 0.4931507
##              [,28]      [,29]      [,30]      [,31]      [,32]
## elements      20.0000000 20.7000000 21.0000000 21.6000000 22.0000000
## acum_rel_fvalues 0.5068493 0.5205479 0.5342466 0.5479452 0.5616438
##              [,33]      [,34]      [,35]      [,36]      [,37]
## elements      24.0000000 24.100000 25.0000000 26.0000000 27.0000000
## acum_rel_fvalues 0.6164384 0.630137 0.6575342 0.6849315 0.7260274
##              [,38]      [,39]      [,40]      [,41]      [,42]
## elements      28.0000000 29.0000000 30.0000000 31.400000 32.0000000
## acum_rel_fvalues 0.7534247 0.7671233 0.8767123 0.890411 0.9041096
##              [,43]      [,44]      [,45]      [,46] [,47]
## elements      33.0000000 34.0000000 34.8000000 38.0000000 46
## acum_rel_fvalues 0.9315068 0.9589041 0.9726027 0.9863014 1

```

Se puede comprobar que son correctos, ya que la frecuencia absoluta acumulada del último elemento es igual al número total de elementos (73) y la frecuencia relativa acumulada del último elemento es 1.

Prosiguiendo con el análisis de datos, se tiene que obtener la media aritmética del conjunto de datos. Para ello, se propone la siguiente función, la cual va a sumar todos los elementos de la muestra, y ese resultado se divide entre el número total de elementos de la muestra.

```

fcd_mean = function(list) {
  add = 0
  for (i in 1:len(list)) {
    add = add + list[i]
  }
  add / len(list)
}

```

Se comprueba el funcionamiento de esta función, obteniendo una media de 18.53.

```

(media_aritm = fcd_mean(distancias))

## [1] 18.53425

```

También se ha de calcular la moda del conjunto de datos. Para ello se ha elaborado una función que calculará este valor. Con ayuda de las frecuencias absolutas, se pueden iterar y buscar la mayor frecuencia, cuyo elemento asociado será la moda. Se va iterando la

frecuencia de cada elemento diferente de la lista y se comprueba si su frecuencia es la mayor hasta el momento. En caso de serlo, la moda temporal corresponderá a ese elemento. Así se observarán todos los elementos, devolviendo después de terminar la iteración de la lista el elemento con mayor frecuencia, la moda. El código que incluye esta funcionalidad es el siguiente:

```
mode = function(list) {
  frequencies = absolute_freq(list)
  elements = frequencies[1,]
  freq_values = frequencies[2,]
  actual_mode = 0
  actual_mode_val = 0
  for (i in 1:len(elements)) {
    if (freq_values[i] > actual_mode_val) {
      actual_mode_val = freq_values[i]
      actual_mode = elements[i]
    }
  }
  actual_mode
}
```

Se extrae la moda del conjunto de datos proporcionado:

```
(moda = mode(distancias))

## [1] 30
```

Se observa que la moda del conjunto de distancias es 30. Se puede comprobar que es correcto si se observan las frecuencias absolutas, ya que el elemento que más veces aparece es el 30 con una frecuencia absoluta de 8. Cabe destacar que en caso de haber dos o más elementos con la misma mayor frecuencia del conjunto de datos, el algoritmo devolverá el elemento de menor magnitud al iterar de menor a mayor elemento.

El siguiente análisis que se hará es el de la mediana, que se ha visto que es el dato que divide en dos al conjunto total de datos. Para calcular este valor se tendrá que observar la paridad del número total de datos. Para saber si  $n$  es par, basta con calcular  $n \pmod{2}$ . Si  $n \equiv 0 \pmod{2}$  será par, y si  $n \pmod{2} \equiv 1$ , será impar.

En caso de tener un número de elementos par, se cogerá de la lista ordenada el elemento  $\frac{n}{2}$  y el elemento  $\frac{n}{2} + 1$ , sumarlos y dividir entre dos. En caso de tener un número de elementos impar directamente se tendrá que coger el elemento  $\frac{n+1}{2}$ .

Se han englobado estos cálculos en una función, donde se comprueba si se está ante un número de elementos par o impar, y se accede a los elementos correspondientes. La función es la siguiente:

```

median_value = function(list) {
  n = len(list)
  ordered_list = bubble(list)
  if (n%%2 == 0) {
    median = (ordered_list[n/2] + ordered_list[(n/2)+1]) / 2
  } else {
    median = ordered_list[(n+1)/2]
  }
  median
}

```

Comprobación del valor de la mediana del conjunto de datos:

```

(mediana = median(distancias))

## [1] 20

```

Se observa que el valor medio es 20. Esto es correcto, ya que si se observa el conjunto ordenado, se ve que existen 73 datos, luego  $\tilde{x}$  será el elemento  $x_{\frac{73+1}{2}} = x_{37} = 20$ , el valor obtenido como mediana.

A continuación se estudiarán dos medidas de dispersión. La primera de las medidas que se van a calcular es la desviación típica. Para ello se ha codificado la siguiente función:

```

standard_dev = function(list) {
  mean = fcd_mean(list)
  n = len(list)
  add = 0
  for (i in 1:n) {
    add = add + ((list[i] - mean)^2)
  }
  sqrt(add/n)
}

```

Como se puede observar, la función consiste en ir sumando las diferencias entre cada dato y la media de todos ellos elevadas al cuadrado,  $(x_i - \bar{x})$ . El bucle `for` de la función es el encargado de realizar esta tarea. Tras ello, se divide el resultado entre el número total de datos  $n$ , y se realiza la raíz cuadrada de la medida obtenida. La desviación típica, por tanto, obedece a la fórmula:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

La desviación típica del conjunto de datos será la siguiente:

```
(desviacion = standard_dev(distancias))

## [1] 11.23204
```

La segunda y última medida de dispersión que se estudiará es la varianza, que en el fondo, no es más que elevar la desviación típica al cuadrado.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

```
variance = function(list) {
  dev = standard_dev(list)
  var = dev^2
  var
}
```

Con esta función, se calcula la varianza del conjunto de datos:

```
(varianza = variance(distancias))

## [1] 126.1587
```

Terminadas las medidas de dispersión, se procede a calcular los cuantiles. Para calcular los cuantiles se tendrá que definir, la lista de la que se quiere calcular el valor, además de  $c$ , que es la porción de valores que se busca. Esto último tendrá que corresponder a un valor entre 0 y 1 en función de  $c$ . Así, si se introduce por parámetro un  $c$  que no es válido se devolverá NULL, ya que no se puede hacer el cálculo. En caso de haber introducido un  $c$  válido se observan dos casos.

- Si  $nc \in \mathbb{N}$  (siendo  $n$  el número total de elementos), se calculará  $\frac{x_{nc} + x_{nc+1}}{2}$ .
- Si  $nc \notin \mathbb{N}$  (siendo  $n$  el número total de elementos), se deberá coger el elemento  $\lfloor nc \rfloor + 1$  o  $\lceil nc \rceil$ .

Con estos cálculos se codifica una función que calcula los cuantiles. La función es la siguiente:

```
quant = function(list, c) {
  ordered_list = bubble(list)
  n = len(list)
  if (c < 0 | c > 1) {
    quant = NULL
  } else if ((n*c)%1 == 0) {
```

```

        quant = (ordered_list[(n*c)] + ordered_list[(n*c) + 1]) / 2

    } else {
        int_prod = floor(n*c)
        quant = ordered_list[int_prod + 1]
    }
    quant
}

```

Para poder comprobar si  $nc \in \mathbb{N}$ , se calcula  $nc \pmod{1}$ , pues  $\forall a \in \mathbb{Z}, a \equiv 0 \pmod{1}$ . Además, se garantiza que  $nc \in \mathbb{Z} \rightarrow nc \in \mathbb{N}$ . Esto es por dos razones fundamentales:

- Siempre se cumplirá que  $n > 0$ .
- Siempre se cumplirá que  $0 < c < 1$ .

En caso de que  $nc \notin \mathbb{N}$  se trabajará con  $\lfloor nc \rfloor$ . Para calcularla se ha hecho uso de la función `floor` perteneciente al paquete `base`. Esta función recoge como parámetro un número y devuelve su aproximación en número entero redondeado hacia abajo. Por ejemplo, si se aplica esta función a 4,99, devolverá 4, pues  $\lfloor 4,99 \rfloor = 4$ .

Con esta función se podrán calcular cuantiles, entre los que se incluyen cuartiles, deciles, percentiles, etc. Para probar la función se calculan los tres cuartiles  $\frac{1}{4}$ ,  $\frac{2}{4}$  y  $\frac{3}{4}$ .

```

(cuartil1 = quant(distancias,0.25))

## [1] 8.1

(cuartil2 = quant(distancias,0.5))

## [1] 20

(cuartil3 = quant(distancias,0.75))

## [1] 28

(cuartilerr = quant(distancias, -0.2))

## NULL

```

Se observa que los valores de  $\tilde{x}_{\frac{1}{4}}$ ,  $\tilde{x}_{\frac{2}{4}}$ ,  $\tilde{x}_{\frac{3}{4}}$  son 8,1, 20 y 28. Además, se ha probado a meter un valor de  $c$  no válido y se verifica que efectivamente se devuelve `NULL`, ya que ese cálculo no sería lógicamente correcto. También se comprueba que  $\tilde{x}_{\frac{2}{4}} = \tilde{x}$  que se ha calculado previamente. Ambos valores deben coincidir ya que hacen referencia al mismo elemento que realiza la misma división de los datos.

## 2.2. Asociación

**Ejercicio 2.2.1.** *El segundo conjunto de datos, que se empleará para realizar el análisis de asociación, estará formado por las siguientes conjuntos de extras incluidos en 8 ventas de coches:  $\{X, C, N, B\}$ ,  $\{X, T, B, C\}$ ,  $\{N, C, X\}$ ,  $\{N, T, X, B\}$ ,  $\{X, C, B\}$ ,  $\{N\}$ ,  $\{X, B, C\}$ ,  $\{T, A\}$ . Donde:  $\{X$ : Faros de Xenon,  $A$ : Alarma,  $T$ : Techo Solar,  $N$ : Navegador,  $B$ : Bluetooth,  $C$ : Control de Velocidad $\}$ , son los extras que se pueden incluir en cada coche.*

Para realizar el algoritmo *apriori* es necesario programar previamente algunas funciones auxiliares que ayudarán a trabajar con conjuntos. Las funciones necesarias en este caso son la unión y la diferencia de conjuntos. La unión de dos conjuntos  $A \cup B$  resulta en un nuevo conjunto que contiene todos los elementos de  $A$  y todos los elementos de  $B$  que no están en  $A$ . Por otro lado, la diferencia de dos conjuntos  $A \setminus B$  da como resultado un nuevo conjunto que contiene todos los elementos de  $A$  que no formen parte de  $B$ . Como función auxiliar también se hará uso de la función `len`, explicada en la Sección 2.1.

```
union = function(c1, c2) {
  if (len(c1) == 0) {
    c2
  } else if (is.element(c1[1], c2)) {
    union(c1[-1], c2)
  } else {
    union(c1[-1], append(c2, c1[1]))
  }
}

dif = function(c1, c2) {
  res = c()
  for (element in c1) {
    if (!(element %in% c2)) {
      res = append(res, element)
    }
  }
  res
}
```

Tras codificar las funciones auxiliares sobre conjuntos, se va a proceder a programar el algoritmo. Para ello, lo primero será trabajar la entrada de datos. Se hará uso de las funciones `get_elements` y `get_table`.

```
get_elements = function(data) {
  elements = c()
  for (i in 1:len(data)) {
    elements = union(elements, data[[i]])
  }
}
```

```

    elements
  }

get_table = function(data, elements) {
  nCol = len(elements)
  nRow = len(data)
  table = data.frame(matrix(0, ncol = nCol, nrow = nRow,
    dimnames = list(1:nRow, elements)))

  for (i in 1:nRow) {
    for (j in 1:len(data[[i]])) {
      table[i, data[[i]][j]] = 1
    }
  }
  table
}

```

La primera de ellas, recibe una serie de listas que representa la muestra, por ejemplo dada la siguiente muestra

$$M = [\underbrace{\{\alpha_1, \alpha_2, \dots, \alpha_n\}}_{L_1}, \underbrace{\{\beta_1, \beta_2, \dots, \beta_m\}}_{L_2}, \dots, \underbrace{\{\gamma_1, \gamma_2, \dots, \gamma_p\}}_{L_n}],$$

se calcula  $\bigcup_{i=1}^n L_i$  para hallar el espacio muestral. Supongamos que tenemos {Pan, Agua, Leche}, {Pan, Agua}, y {Pan, Leche}. Calculando la unión se obtiene  $E = \{\text{Pan, Agua, Leche}\}$ .

La segunda de ellas crea una matriz (codificado por un dataframe) que representa por filas los sucesos de la muestra, y por columnas los sucesos elementales, encontrándose en la entrada  $a_{ij}$  un valor binario representando si dicho suceso elemental se encuentra en el suceso de la muestra. Retomando el ejemplo anterior se tendría la siguiente matriz.

$$\begin{pmatrix} 1 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

```

m = list(c("Pan", "Agua", "Leche"), c("Pan", "Agua"), c("Pan", "Leche"))
eltos = get_elements(m)
(get_table(m, eltos))

##   Pan Leche Agua
## 1   1     1    1
## 2   1     0    1
## 3   1     1    0

```



A continuación se va a realizar una función que cuente las apariciones de una serie de sucesos en la muestra. Se sumará uno al contador cuando todos los elementos del suceso que se está estudiando aparezcan en el mismo suceso de la muestra. La función es la siguiente:

```
count_appearance = function(table, elements) {
  count = 0
  for (i in 1:len(table[,1])) {
    acum = 1
    for (element in elements) {
      acum = (table[i,element]) & acum
    }
    count = count + acum
  }
  count
}
```

El objetivo de esta función, es dado un conjunto  $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ , contar cuántas veces es subconjunto de sucesos de la muestra. Para ello, siendo  $\beta_{im}$  el elemento  $m$ -ésimo del suceso de la muestra  $i$ -ésimo, se realiza la siguiente operación:

$$\sum_{i=1}^{nrows} \bigwedge_{m=1}^{ncol} \beta_{im}$$

La siguiente herramienta que se necesita en el algoritmo apriori es el soporte, que queda definido de la siguiente manera.

#### Definición 2.2.1: Soporte

$$\forall \{A_i\}_{i=1}^{\infty} \subset P(E) \text{ con } A_i \cap A_j \neq \emptyset \forall i \neq j,$$

$$s : P(E) \longrightarrow \mathbb{R}^+ \text{ tal que } s(A_i \cup A_j) = \frac{n_{A_i \cup A_j}}{n_T}$$

Como se puede observar, la función `count_appearance` que se había codificado previamente, será de ayuda para calcular el soporte, de forma que ahora basta dividir el resultado de esta por el número de sucesos de la muestra tal y como se hace en la función `support`.

```
support = function(table, elements) {
  count_appearance(table, elements) / len(table[,1])
}
```

Siendo el primer paso del algoritmo el descarte de los sucesos elementales que no superan el umbral de soporte, esto se logra con la función `support_clasif` iterando cada suceso elemental y calculando su soporte mediante las funciones ya explicadas.

```

support_clasif = function(table, ocurrences, s) {
  valid_ocurrences = list()
  for (ocurrence in ocurrences) {
    support_oc = support(table, ocurrence)
    if (support_oc >= s) {
      valid_ocurrences = append(
        valid_ocurrences, list(ocurrence))
    }
  }
  valid_ocurrences
}

```

Una vez calculados aquellos sucesos elementales que superan el umbral del soporte, se deberá aplicar el método  $F_{k-1} \times F_{k-1}$  de **apriori-gen** para construir los conjuntos candidatos de dimensiones superiores. En cada iteración del algoritmo, este toma dos sucesos de dimensión  $k-1$ ,  $\alpha = \{\alpha_1, \alpha_2, \dots, \alpha_{k-1}\}$  y  $\beta = \{\beta_1, \beta_2, \dots, \beta_{k-1}\}$  para formar un tercer conjunto de dimensión  $k$  de la forma  $\{\alpha_1, \alpha_2, \dots, \alpha_{k-2}, \alpha_{k-1}, \beta_{k-1}\}$  o  $\{\beta_1, \beta_2, \dots, \beta_{k-2}, \beta_{k-1}, \alpha_{k-1}\}$ . En definitiva, se calcula  $\alpha \cup \beta$  sólo si se cumplen las siguientes condiciones:

- $\forall i \leq k-2, \alpha_i = \beta_i$
- $\alpha_{k-1} \neq \beta_{k-1}$

Para implementar este algoritmo se necesitarán algunas funciones auxiliares que se presenten a continuación. La primera de ellas será **equals**, que será la encargada de verificar si para dos listas  $L_1$  y  $L_2$ , se cumple que  $\forall i L_{1i} = L_{2i}$ .

```

equals = function(l1, l2) {
  n = len(l1)

  if (n != len(l2)) return(FALSE)
  if (n==0) return(TRUE)

  for (i in 1:n) if (l1[i] != l2[i]) return(FALSE)
  TRUE
}

```

Las dos siguientes son **front** y **back**. Dada una lista y un valor natural, **front** devuelve otra lista que es una partición de la original hasta el índice del valor indicado. De la misma forma, **back** devuelve la lista que contiene los últimos valores indicados. Ambas funciones hacen uso de las funciones **head** y **tail** (del paquete **utils**) respectivamente, pero devolviendo NULL si el numero de elementos a seleccionar es menor o igual a 0.

```

front = function(l, n) {
  if (n <= 0) return(NULL)
  head(l, n)
}

back = function(l, n) {
  if (n <= 0) return(NULL)
  tail(l, n)
}

```

Como se verá a continuación al explicar el funcionamiento del algoritmo, se necesitará calcular el número combinatorio  $\binom{n}{k}$ , que representa el número de subconjuntos de tamaño  $k$  que tiene un conjunto de tamaño  $n$ . Para realizar su cálculo, se ha programado un algoritmo de programación dinámica que se ejecuta en un tiempo de  $\mathcal{O}(n^2)$ . En primer lugar, el número combinatorio se define como

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

por lo que fácilmente se ve que  $\binom{n}{0} = 1$ , y que también  $\binom{n}{n} = 1$ , pues de la definición se deduce que

$$\binom{n}{k} = \binom{n}{n-k}.$$

Con estas dos identidades y la que se presenta a continuación, se puede calcular cualquier número binomial como suma de otros dos, partiendo del caso en el que vale 1.

$$\begin{aligned}
 \binom{n}{k} &= \frac{n(n-1)!}{k!(n-k)!} \\
 &= \frac{(n-1)!k}{k!(n-k)!} + \frac{(n-1)!(n-k)}{k!(n-k)!} \\
 &= \frac{(n-1)!k}{k(k-1)!(n-k)!} + \frac{(n-1)!(n-k)}{k!(n-k)(n-k-1)!} \\
 &= \frac{(n-1)!}{(k-1)!(n-k)!} + \frac{(n-1)!}{k!(n-k-1)!} \\
 &= \binom{n-1}{k-1} + \binom{n-1}{k}
 \end{aligned}$$

En el código que se muestra, se aplica esta relación de recurrencia rellenando una matriz, de forma que se calcula sin aplicar recursividad, ya que tendría una complejidad superior, lo que empeoraría aún más el tiempo de ejecución del algoritmo apriori.

```

binom = function(n, k) {
  temp = matrix(0, nrow = n + 1, ncol = k + 1)
  for (i in 0:n) {
    for (j in 0:min(i, k)) {
      if (j == 0 || j == i) {
        temp[i + 1, j + 1] = 1
      } else {
        temp[i + 1, j + 1] =
          temp[i, j] + temp[i, j + 1]
      }
    }
  }
  temp[n + 1, k + 1]
}

```

Finalmente, la función `fk_1` representa el algoritmo al completo. El algoritmo funciona alrededor de ir añadiendo subconjuntos candidatos calculados en iteraciones previas a un vector. El algoritmo recibe una lista de los sucesos elementales que han superado el umbral de soporte establecido en el paso previo del algoritmo, y con `lapply` añade al vector mencionado previamente los que serían los conjuntos candidatos de dimensión 1. El algoritmo sigue con las sucesivas dimensiones, y en la dimensión  $k$  combina los sucesos candidatos de dimensión  $k - 1$  dos a dos, obtenidos en la iteración previa. Para cada posible pareja, se comprueban las dos reglas explicadas previamente con ayuda de las funciones `front` y `back`. Aquellas que verifican ambas reglas, se añaden al vector comentado como candidatos de dimensión  $k$ .

En cada iteración será necesario saber en qué posición del vector inicia y finalizan los sucesos candidatos de dimensión  $k - 1$ . Suponiendo que se tienen  $n$  sucesos elementales, la posición del primer suceso de dimensión  $k$ , viene dada por sumar a la posición del primer suceso de dimensión  $k - 1$ , el número combinatorio  $\binom{n}{k}$ , pues  $F_{k-1} \times F_{k-1}$  irá añadiendo los posibles subconjuntos.

Finalmente, se devuelve el vector sobre el que se ha trabajado pero recortándolo de forma que no aparezcan los sucesos de dimensión 1, pues al formar asociaciones con estos, uno de los dos sucesos que la formarían sería  $\emptyset$ , cosa que no tiene sentido.

```

fk_1 = function(clasif) {
  comb = lapply(clasif, c)
  n = len(clasif)
  n_comb = n
  start = 1

  for (k in 2:n) {

```

```

        for (i in start:(n_comb-1)) {
            for (j in (i+1):n_comb) {

                hd1 = front(comb[[i]], len(comb[[i]])-1)
                hd2 = front(comb[[j]], len(comb[[j]])-1)

                t11 = back(comb[[i]], 1)
                t12 = back(comb[[j]], 1)

                if (equals(hd1, hd2) & !equals(t11, t12)) {
                    new = c(hd1, t11, t12)
                    comb = c(comb, list(new))
                }
            }
        }
        start = n_comb + 1
        n_comb = n_comb + binom(n, k)
    }
    back(comb, n_comb-n)
}

confidence = function(table, left, right) {
    count_appearance(table, union(left, right)) /
    count_appearance(table, left)
}

```

De la misma manera que se ha necesitado calcular el soporte, también se necesitará calcular la confianza, definida como se muestra en la Definición 2.2.2. Se implementa con la función previamente mostrada **confidence**.

#### Definición 2.2.2: Confianza

$$\forall \{A_i\}_{i=1}^{\infty} \subset P(E) \text{ con } A_i \cap A_j \neq \emptyset \forall i \neq j,$$

$$c : P(E) \longrightarrow \mathbb{R}^+ \text{ tal que } c(A_i \cup A_j) = \frac{n_{A_i \cup A_j}}{n_{A_i}}$$

```

get_associations = function(candidates) {
    associations = data.frame()
    lapply(candidates, function(x) {
        k = len(x)
        for (dim in 1:(k - 1)) {
            left_sides = combn(x, m=dim, simplify=TRUE)
            for (col in 1:len(left_sides[1,])) {
                left_side = left_sides[, col]
            }
        }
    })
}

```

```

        right_side = dif(x, left_side)
        new_assoc = data.frame(
            left = I(list(left_side)),
            right = I(list(right_side)))
        associations <- rbind(
            associations, new_assoc)
    }
}
}))
associations
}

```

La función `get_associations` recibe como parámetro una lista con los sucesos que han superado el soporte, y en un dataframe de dos columnas se guardarán las posibles asociaciones ( $A \rightarrow B - A$ ), representando la primera columna los lados izquierdos de las asociaciones, y la segunda los derechos. Para cada candidato ( $B$ ), se define una lista con todas las posibles combinaciones de elementos que puedan haber en el lado izquierdo ( $A$ ), siendo estas todas las representadas por los  $\sum_{i=1}^{k-1} \binom{n}{i}$  subconjuntos. Estos posibles subconjuntos de  $B$ , se obtienen mediante la función `combn` del paquete `utils`, que recibe como parámetros el conjunto del que obtener subconjuntos, el tamaño de los subconjuntos ( $i$ ), y si importa el orden o no (en este caso no). El lado derecho o  $B - A$ , se calcula mediante la diferencia de los conjuntos  $B$  y  $A$ . Finalmente, se va modificando el dataframe original para añadir asociaciones. Al estar en un ámbito superior se utiliza `<-`.

```

indexOf_assoc = function(df, left_side, right_side) {
    found = FALSE
    i = 1
    while(!found & i <= len(df[,1])) {
        found = equals(df[i, "left"][[1]], left_side) &
            equals(df[i, "right"][[1]], right_side)
        i = i + 1
    }
    i-1
}

```

La función `indexOf_assoc`, es una función auxiliar de `ap_genrules` que dados los dos sucesos de una asociación, devuelve el índice del dataframe en el que se encuentra.

```

ap_genrules = function(table, assoc, c) {
    assoc = cbind(assoc, data.frame(matrix(1, ncol = 1,
        nrow = len(assoc[,1]), dimnames = list(1:len(assoc[,1]), "valid"))))
    for (i in len(assoc[, "left"]):1) {
        A = assoc[i, "left"][[1]]
        right = assoc[i, "right"][[1]]
        B = union(A, right)
    }
}

```

```

        if (assoc[i, "valid"]) {
          conf = confidence(table, A, right)
          if (conf < c) {
            for (j in 1:len(A)) {
              A_primes = unlist(combn(A, m=j, simplify=TRUE))
              for (k in seq(1, len(A_primes), by=j)) {
                new_left = A_primes[k:(k+j-1)]
                new_right = dif(B, new_left)
                index = index0f_assoc(
                  assoc, new_left, new_right)
                assoc[index, "valid"] = 0
              }
            }
          }
        }
      }
    }
  }
  subset(assoc, assoc$valid == 1)
}

```

#### Teorema 2.2.1: ap-genrules

Sean dos conjuntos  $A$  y  $B$ , si la asociación  $A \rightarrow B - A$  no supera el umbral de confianza, entonces cualquier asociación  $A' \rightarrow B - A'$ , donde  $A'$  es cualquier subconjunto de  $A$  ( $A' \subseteq A$ ), tampoco la alcanzará.

La función `ap.genrules` irá marcando qué asociaciones superan el umbral de confianza. Para ello, añade al dataframe de `get.associations` una columna en la que “marcar” si cada asociación pasa el umbral de confianza (✓) o no (×). Para cada asociación de la forma  $A \rightarrow B - A$  se toman los conjuntos  $A$  cuyo tamaño sea mayor, y se obtienen los conjuntos  $B$  y  $B - A$  correspondientes para si dicha asociación había sido marcada con ✓ o ×. En caso de estar marcada como ✓ se pasa a la siguiente asociación, y en caso contrario, se calcula si supera el umbral de confianza establecido (marcándola como ✓) y si no lo hace, se aplica el Teorema 2.2.1. Finalmente, se devuelve en un dataframe aquellas asociaciones del dataframe marcadas con ✓ mediante la función `subset`, del paquete `base`.

```

print_associations = function(left_list, right_list) {
  left_side = paste(left_list[[1]], collapse = ",")
  right_side = paste(right_list[[1]], collapse = ",")
  cat("{")
  cat(left_side)
  cat("} --> {")
  cat(right_side)
  cat("}\n")
}

```

Mediante la función `print_associations`, dados los dos sucesos que forman una asociación, imprime esta de la forma  $\{...\} \rightarrow \{...\}$ . Aquí se hace uso de `cat`, función contenida en el paquete `base` y que permite realizar salidas por pantalla con argumentos. En este caso, se desea imprimir por pantalla, además de un mensaje, el valor de `left_sidey`

### 2.2.1. Técnicas estadísticas

**Ejercicio 2.2.2.** *El tercer conjunto de datos, que se empleará para realizar el análisis de detección de datos anómalos utilizando técnicas con base estadística, estará formado por los siguientes 10 valores de velocidades de respuesta y temperaturas normalizadas de un microprocesador {Velocidad, Temperatura}: {10, 7.46; 8, 6.77; 13, 12.74; 9, 7.11; 11, 7.81; 14, 8.84; 6, 6.08; 4, 5.39; 12, 8.15; 7, 6.42; 5, 5.73}. Aplicar las medidas de ordenación a la velocidad y las de dispersión a la temperatura.*

Como se ha visto previamente, el cálculo de *outliers* por medio de técnicas con base estadística no proporcionaban los mismos resultados que los vistos en clase, ya que hay ciertos cálculos (como el de los cuartiles o la desviación) que están realizados de forma diferente a como se ha estudiado; y esto implica un error que se propaga al cálculo de los intervalos para valores atípicos y por consecuente al resultado final. En la Sección 2.1 se han realizado funciones propias que proporcionan los resultados correctos a los cálculos. Es por ello que, en base a estas funciones, se van a realizar los algoritmos correspondientes.

En primer lugar se van a introducir los datos. Para ello se hará tal y como se ha visto previamente, con la función `matrix`, de tal forma que esta tenga dos columnas (una para velocidad y otra para temperatura) y tantas filas como entradas de datos se tengan. Tras ello, se pasa esta matriz a un dataframe para operar sobre los datos de una forma más cómoda. El resultado es el siguiente:

```
muestra = t(matrix(c(10,7.46,8,6.77,13,12.74,9,7.11,11,7.81,14,8.84,6,
6.08,4,5.39,12,8.15,7,6.42,5,5.73),
2,11,dimnames=list(c("velocidad","temperatura"))))
(muestra=data.frame(muestra))
```

```
##      velocidad temperatura
## 1           10          7.46
## 2            8          6.77
## 3           13         12.74
## 4            9          7.11
## 5           11          7.81
## 6           14          8.84
## 7            6          6.08
## 8            4          5.39
## 9           12          8.15
## 10           7          6.42
## 11           5          5.73
```



Se observa que se tienen los datos dispuestos en dos columnas, una para velocidad y otra para temperatura. También se tienen 11 filas, que corresponde con el número total de parejas (velocidad, temperatura) entrantes al conjunto de datos.

### Caja y bigotes

Con los datos organizados se puede empezar a trabajar. Lo primero de todo será aplicar las medidas de ordenación a la velocidad. Esto quiere decir aplicar el algoritmo de caja y bigotes visto en la Sección 1.3.1. Primeramente, se va a centrar la atención en la columna velocidad, que es la que interesa ahora:

```
muestra_velocidad = muestra$velocidad
```

Con esta línea de código se guarda la columna de velocidad, y se podrá llamar a la función que implementa el algoritmo directamente con muestra\_velocidad. Una vez se tiene todo listo, este es el código del algoritmo.

```
boxNmustaches = function(sample, d, details = FALSE) {
  outliers = c()
  cuart1 = quant(sample, 0.25)
  cuart3 = quant(sample, 0.75)
  lim_inf = cuart1 - (d*(cuart3-cuart1))
  lim_sup = cuart3 + (d*(cuart3-cuart1))

  if(details) {
    print("->PASO 1: DETERMINACIÓN DEL GRADO DE OUTLIER")
    cat("Grado de outlier d = ",d,"\n\n")

    print("->PASO 2: CÁLCULO CUARTILES 1 Y 3")
    cat("El cuart. 1 es ",cuart1, " y el cuart. 3 es ", cuart3,"\n\n")

    print("->PASO 3: CÁLCULO DEL INTERVALO")
    cat("Fórmula -> (Q1 - d*(Q3-Q1), Q3 + d*(Q3-Q1))\n")
    cat("Intervalo: (",lim_inf,", ",lim_sup,")\n\n")

    print("->PASO 4: IDENTIFICACIÓN DE OUTLIERS")
  }

  for (i in 1:len(sample)) {
    if(sample[i] < lim_inf || sample[i] > lim_sup) {
      outliers = append(outliers, i)
      if(details) {
        cat("El punto ",i," con valor ",sample[i],
          " es un outlier\n")
      }
    }
  }
}
```

```

    }
    if(len(outliers) == 0) {
        cat("No hay outliers")
    }
    outliers
}

```

Para comenzar, la función recibe los siguientes parámetros:

- `sample`: El data frame con los datos correspondientes. En este caso, `muestra_velocidad`.
- `d`: El grado de *outlier* a partir del cual un dato se considera anómalo. Servirá para calcular el intervalo para valores atípicos.
- `details`: Es un parámetro que por defecto estará a `FALSE`, y que servirá para que el usuario indique si quiere una salida detallada o sencilla. Con salida sencilla se refiere a una lista con los índices de los puntos que se han evaluado como *outliers*, mientras que con salida detallada se devolverá esto mismo además de una serie de mensajes por pantalla donde se detalla cada paso y lo que se hace en él, así como los resultados parciales que se han ido obteniendo.

A partir de la salida detallada se irá explicando poco a poco el algoritmo.

1. En este paso se determina el grado de outlier, que es elegido arbitrariamente por el usuario. Esta parte del algoritmo no es más que reescribir el parámetro `d` que ha introducido a la hora de llamar a la función. Además, se hace uso de `cat`, función ya vista previamente.
2. En este paso se van a calcular los cuartiles 1 y 3 (0,25 y 0,75) para posteriormente utilizarlos en el cálculo del intervalo para valores atípicos. Se observa que se hace uso de la función `quant`, definida en la Sección 2.1. Además, si el usuario lo desea, se imprime por pantalla el valor de ambos.
3. Una vez calculados los cuartiles, se va a calcular el intervalo que permitirá clasificar los *outliers*. Para ello se calculan `lim_inf` y `lim_sup` que serán los límites inferior y superior respectivamente, ambos mediante la Ecuación (1.1). El hecho de haber utilizado la función propia `quant` para el cálculo de los cuartiles permite que el intervalo sea ahora el mismo que el obtenido en clase de teoría.
4. Por último, se recorren todos los datos y se buscan aquellos que estén por debajo del límite inferior o por encima del límite superior, ya que al no estar comprendido en el intervalo, se consideran datos anómalos. Además, se añaden a una lista `outliers` (previamente vacía) estas anomalías para posteriormente devolverlas.

Con este algoritmo se va a resolver el ejercicio. Se llamará a la función `boxNmustache` con `muestra_velocidad` y un valor  $d = 1,5$ .

```
anomalias_vel = boxNmustaches(muestra_velocidad, 1.5, TRUE)

## [1] "->PASO 1: DETERMINACIÓN DEL GRADO DE OUTLIER"
## Grado de outlier d = 1.5
##
## [1] "->PASO 2: CÁLCULO CUARTILES 1 Y 3"
## El quart. 1 es 6 y el quart. 3 es 12
##
## [1] "->PASO 3: CÁLCULO DEL INTERVALO"
## Fórmula -> (Q1 - d*(Q3-Q1), Q3 + d*(Q3-Q1))
## Intervalo: ( -3 , 21 )
##
## [1] "->PASO 4: IDENTIFICACIÓN DE OUTLIERS"
## No hay outliers
```

Se observa cómo se informa al usuario del grado de *outlier* que ha introducido, de los valores de los cuartiles 1 y 3, de cómo se calcula el intervalo para valores atípicos y de todos aquellos *outliers* que se han encontrado. En este ejemplo concreto no hay *outliers* ya que todos los valores se encuentran dentro del intervalo establecido. Si se quisiera acceder a la lista que contiene todos los *outliers* bastaría con acceder en este ejemplo a `anomalias_vel`.

## Media y desviación

En este segundo apartado del ejercicio se van a detectar anomalías, esta vez sobre la columna de temperatura y aplicando medidas de dispersión. El cálculo del intervalo se realiza esta vez con la media aritmética y la desviación típica. Como se ha ido viendo, el cálculo de la desviación típica mediante la función `sd` es diferente al visto en teoría. Por ello, se puede aplicar la función `standard_dev` elaborada en la Sección 2.1 y que da el valor visto en clase de teoría. Primeramente se guarda la columna de temperaturas para posteriormente trabajar mejor sobre ella.

```
muestra_temp = muestra$temperatura
```

Ya se tienen los datos de temperatura, así que solo queda llamar a la función que implementa este algoritmo. Es bastante similar a la función anterior de `boxNmustache` solo que ahora en vez de calcular cuartiles, se calculan la media aritmética y la desviación típica; y la fórmula del intervalo para valores atípicos también cambia, tal y como se ha visto en la Sección 1.3.1. La función que implementa el algoritmo es la siguiente:

```

dispersed_outliers = function(sample, d, details = FALSE) {
  outliers = c()
  mean_sample = fcd_mean(sample)
  dev_sample = standard_dev(sample)
  lim_inf = mean_sample - (d*dev_sample)
  lim_sup = mean_sample + (d*dev_sample)

  if(details) {
    print("->PASO 1: DETERMINACIÓN DEL GRADO DE OUTLIER")
    cat("Grado de outlier d = ",d,"\n\n")

    print("->PASO 2: CÁLCULO DE LA MEDIA ARITMÉTICA")
    cat("La media aritmética es ", mean_sample, "\n\n")

    print("->PASO 3: CÁLCULO DE LA DESVIACIÓN TÍPICA")
    cat("La desviación típica es ", dev_sample, "\n\n")

    print("->PASO 4: CÁLCULO DEL INTERVALO")
    cat("Fórmula -> (Media - d*DesvTipica, Media + d*DesvTipica)\n")
    cat("El intervalo es: (",lim_inf," ",lim_sup,")\n\n")

    print("->PASO 5: IDENTIFICACIÓN DE OUTLIERS")
  }

  for (i in 1:len(sample)) {
    if(sample[i] < lim_inf || sample[i] > lim_sup) {
      outliers = append(outliers, i)
      if(details) {
        cat("El punto ",i," con valor ",sample[i],
            " es un outlier\n")
      }
    }
  }

  if(len(outliers) == 0) {
    cat("No hay outliers")
  }
  outliers
}

```

Como se puede observar, el código es prácticamente igual. Se pasan los mismos parámetros que en el algoritmo anterior. El primer paso recuerda al usuario el grado de dispersión que ha introducido, y el segundo y tercer paso calculan la media y la desviación típica con las funciones propias que lo hacen como se ha visto en teoría. El cuarto paso calcula los límites del intervalo para valores atípicos haciendo uso de la media y la desviación típica previamente calculadas y con la Ecuación (1.2), y finalmente se recorren todos los datos en busca de

los valores que no están dentro del intervalo calculado.

Al igual que en el algoritmo anterior, se devolverá una lista con los puntos que son *outliers* y se podrá elegir entre una salida detallada con mensajes por pantalla del proceso o una salida limitada a la devolución de la lista de *outliers*. Se comprueba el algoritmo con la temperatura y un grado de dispersión  $d = 2$ :

```
anomalias_temp = dispersed_outliers(muestra_temp, 2, TRUE)

## [1] "->PASO 1: DETERMINACIÓN DEL GRADO DE OUTLIER"
## Grado de outlier d = 2
##
## [1] "->PASO 2: CÁLCULO DE LA MEDIA ARITMÉTICA"
## La media aritmética es 7.5
##
## [1] "->PASO 3: CÁLCULO DE LA DESVIACIÓN TÍPICA"
## La desviación típica es 1.935933
##
## [1] "->PASO 4: CÁLCULO DEL INTERVALO"
## Fórmula -> (Media - d*DesvTipica, Media + d*DesvTipica)
## El intervalo es: ( 3.628134 , 11.37187 )
##
## [1] "->PASO 5: IDENTIFICACIÓN DE OUTLIERS"
## El punto 3 con valor 12.74 es un outlier
```

Se observa cómo se ha ido haciendo todo el proceso (pues se ha elegido una salida detallada) y se ve que al final se ha encontrado una anomalía en el punto 3 cuyo valor es 12,74, el cual se encuentra fuera del intervalo, por lo que es considerado un *outlier*.

Si se quisiera acceder a la lista de los puntos que son *outliers* bastaría con acceder a la variable a la que se ha igualado la llamada de la función. En este caso habría que acceder a `anomalias_temp`.

```
anomalias_temp

## [1] 3
```

Y efectivamente se tiene una lista con un 3, el punto que se ha visto que era un *outlier*.

### 2.2.2. Técnicas de proximidad y densidad

**Ejercicio 2.2.3.** *El cuarto conjunto de datos, que se empleará para realizar el análisis de detección de datos anómalos utilizando técnicas basadas en la proximidad y en la densidad,*

estará formado por el número de Mujeres y Hombres inscritos en una serie de cinco seminarios que se han impartido sobre biología. Los datos son: {Mujeres, Hombres}: 1. {9, 9}; 2. {9, 7}; 3. {11, 11}; 4. {2, 1}; 5. {11, 9}.

### Algoritmo $k$ -vecinos

En primer lugar se va a resolver el ejercicio con técnicas basadas en proximidad (algoritmo  $k$ -vecinos). Para ello se programará una función principal y funciones auxiliares que vaya necesitando esta primera, con el objetivo de devolver aquellos datos que se consideran anomalías. El funcionamiento del algoritmo es el siguiente:

Para empezar, a partir de ahora cada suceso de la muestra se considerará como un punto en el plano, cuya componente  $x$  será el número de mujeres y cuya componente  $y$  será el número de hombres. Así se deberá determinar el grado de *outlier* o distancia  $d$  a partir de la cual un punto es considerado como un dato anómalo. Además se deberá determinar el número de orden o  $k$ -vecino más próximo. Ambos parámetros se eligen arbitrariamente, por lo que quedarán a juicio del analista. La programación del algoritmo facilitará la posibilidad de introducir ambos parámetros.

Una vez determinados  $d$  y  $k$  se deberán calcular las distancias euclídeas de cada punto al resto de puntos. La distancia euclídea en el problema es definida mediante la siguiente fórmula:

$$\text{dist}(p_i, p_j) = \sqrt{(p_{i1} - p_{j1})^2 + (p_{i2} - p_{j2})^2}$$

Es por ello que se necesita una función que permita obtener el valor de la distancia euclídea entre dos puntos. Se propone la siguiente:

```
euc_distance = function(p1,p2) {
  if(len(p1) == len(p2)) {
    add = 0
    for(i in 1:len(p1)) {
      add = add + ((p1[i] - p2[i])^2)
    }
    sqrt(add)
  } else {
    print("No se puede calcular la distancia euclídea")
  }
}
```

Los parámetros  $p1$  y  $p2$  que recibe la función representan dos listas; ambas contienen los valores de las componentes de cada punto. Ambos puntos deberán tener el mismo número de componentes para poder calcularse la distancia euclídea. De esta forma se restan los valores de cada componente y se eleva al cuadrado, añadiéndose este valor a un acumulador de todas las diferencias cuadráticas de las componentes,

al cual posteriormente se le aplicará la raíz cuadrada. La distancia euclídea generalizada se puede expresar de esta forma:

$$\text{dist}(p_i, p_j) = \sqrt{\sum_{i=1}^n (p_i - p_j)^2}$$

Una vez se tiene una función capaz de calcular las distancias euclídeas, se ha de elaborar una estructura que pueda recoger la distancia de cada punto al resto de puntos. Es por ello que se propone una matriz de distancias, donde la posición  $(i, j)$  representará la distancia euclídea del punto  $i$  al punto  $j$ . Para ello se ha realizado la siguiente función:

```
create_distance_matrix = function(df) {
  empty_matrix = matrix(ncol = len(df[,1]), nrow = len(df[,1]))
  distances = data.frame(empty_matrix)
  for (i in 1:len(df[,1])) {
    for (j in i:len(df[,1])) {
      dist = euc_distance(df[i,], df[j,])
      distances[i,j] = dist
      distances[j,i] = dist
    }
  }
  distances
}
```

La función `create_distance_matrix` recibe un dataframe (que como se verá más adelante corresponde con la entrada del algoritmo). A partir de ello crea otro dataframe con tantas filas y columnas como puntos haya en la muestra. Así se recorren todos los puntos y se calcula para cada uno su distancia al resto. Teniendo un punto  $i$  y un punto  $j$ , se rellenan las posiciones  $[i, j]$  y  $[j, i]$  del nuevo dataframe. La razón que motiva esta doble asignación es que puede optimizar el algoritmo, ya que la distancia de dos puntos es la misma en un sentido o en otro, por lo que no hace falta volver a calcular la misma distancia en el sentido opuesto.

Con las distancias de todos los puntos ya calculadas, el siguiente paso es ordenar y detectar si la  $k$  distancia más próxima sobrepasa o no el grado de *outlier*  $d$ , ambos definidos por el analista. En caso de sobrepasar  $d$ , el punto es un *outlier* y viceversa. La función que detecta las anomalías de esta forma es la siguiente:

```
detect_outliers = function(sample, distance_matrix, k, d, details) {
  if(details) {
    print("->PASO 3: IDENTIFICACIÓN DE LOS OUTLIERS")
  }
  outliers = c()
```

```

    for (column in 1:len(distance_matrix[1,])) {
        ordered_column = bubble(distance_matrix[column,])
        if (ordered_column[k+1] > d) {
            outliers = append(outliers,column)
            if(details) {
                cat("El punto", column, "(",
                    paste(sample[column,], collapse = ","),
                    ") es un outlier\n")
            }
        }
    }
    outliers
}

```

En el dataframe que había quedado antes se tiene en cada columna  $i$ -ésima las distancias del punto  $i$ -ésimo, por lo que se irá ordenando columna por columna gracias a la función `bubble` realizada en ejercicios anteriores. De esa ordenación bastará con fijarse en la posición  $k+1$  (ya que la primera posición corresponde a la distancia del punto a sí mismo que es 0 y no es considerada un  $k$ -vecino). Si esta es mayor que  $d$  se clasifica al punto como anomalía, en caso contrario no lo será. Se devuelve de esta forma una lista con los puntos que son considerados anomalías.

Una característica de esta función es que si el parámetro `details` (que se verá ahora en más detalle) está a `TRUE`, imprime con `cat` que el punto  $x$  es un *outlier*. Además de imprimir el número  $x$  del punto imprime las componentes que lo forman con la función `paste` que se ha visto en el ejercicio autónomo de asociación, y que pasa la lista con las componentes del punto a cadena, separando cada una con comas gracias al parámetro `collapse = ","`; de tal forma que también se puedan imprimir las componentes del punto.

Por último, se han de unir todos los módulos en una función que encapsule toda esta funcionalidad. Para ello se ha creado la siguiente función, que será a la que llame el usuario cuando quiera ejecutar el algoritmo  $k$ -vecinos:

```

k_neighbors = function(sample, k, d, details = FALSE) {
    if(details) {
        print("->PASO 1: DETERMINACIÓN DE d Y k")
        cat("Grado de outlier: d =",d,"\n")
        cat("K-Vecino más próximo: k =",k,"\n\n")
    }
    d_matrix = create_distance_matrix(sample)
    if(details) {
        print("->PASO 2: MATRIZ DE DISTANCIAS ENTRE PUNTOS:\n")
    }
}

```



```

        print(d_matrix)
        cat("\n")
    }
    detect_outliers(sample, d_matrix, k, d, details)
}

```

La función recibirá cuatro parámetros que se detallan a continuación:

- `sample`: La entrada del algoritmo en formato `dataframe`. Al introducirse en este formato el algoritmo se asegura de que está trabajando con una muestra bien construida, ya que el número de filas y columnas tiene que ser el mismo; en otras palabras, se tendrá el mismo número de componentes para cada suceso de la muestra.
- `k`:  $k$ -vecino más próximo elegido para la ejecución del algoritmo.
- `d`: Distancia o grado de outlier elegido para la ejecución del algoritmo.
- `details`: Por defecto a `FALSE`. Permite mostrar una ejecución detallada de los pasos del algoritmo. Si se pone a `TRUE` imprime por pantalla el valor de los dos parámetros anteriores, la matriz de distancias y todos los puntos que son considerados *outliers* (por eso `details` también se encuentra presente en la función `detect_outliers`. Además devuelve una lista con todos estos puntos. En caso de estar a `FALSE`, se entiende que el usuario no quiere una ejecución detallada, así que solo se devuelve la lista de *outliers*.

La función llama de esta forma a `create_distance_matrix` para crear la matriz de distancias y a `detect_outliers` para clasificar según el algoritmo  $k$ -vecinos.

Se procede a probar la función `k.neighbors` con la muestra del ejercicio. En este caso se opta por realizar una ejecución detallada de la misma.

```

muestra = data.frame("mujeres" = c(9,9,11,2,11), "hombres" = c(9,7,11,1,9))
k_neighbors(muestra,3,3.5,TRUE)

## [1] "->PASO 1: DETERMINACIÓN DE d Y k"
## Grado de outlier: d = 3.5
## K-Vecino más próximo: k = 3
##
## [1] "->PASO 2: MATRIZ DE DISTANCIAS ENTRE PUNTOS:\n"
##           X1          X2          X3          X4          X5
## 1  0.000000  2.000000  2.828427  10.630146  2.000000
## 2  2.000000  0.000000  4.472136   9.219544  2.828427
## 3  2.828427  4.472136  0.000000  13.453624  2.000000
## 4  10.630146  9.219544  13.453624  0.000000  12.041595

```

```
## 5  2.000000 2.828427  2.000000 12.041595  0.000000
##
## [1] "->PASO 3: IDENTIFICACIÓN DE LOS OUTLIERS"
## El punto 2 ( 9,7 ) es un outlier
## El punto 3 ( 11,11 ) es un outlier
## El punto 4 ( 2,1 ) es un outlier
## [1] 2 3 4
```

### Algoritmo LOF

Para resolver este ejercicio de otra forma se empleará el algoritmo LOF o LOCAL OUTLIER FACTOR. Este se basa en las densidades y la distancia Manhattan, que se define de la siguiente forma para los puntos de la muestra:

$$\text{dist}(p_i, p_j) = |p_{i1} - p_{j1}| + |p_{i2} - p_{j2}|$$

Esta distancia se calcula en R mediante la función observada a continuación. Para ello se itera sobre las diferentes componentes de los puntos y se calcula su diferencia en valor absoluto, es decir, se generaliza de la siguiente manera:

$$\text{dist}(p_i, p_j) = \sum_{i=1}^n |p_i - p_j|$$

```
manhattan_distance = function(p1, p2) {
  if(len(p1) == len(p2)){
    add = 0
    for(i in 1:len(p1)) {
      add = add + abs(p1[i] - p2[i])
    }
    add
  } else {
    print("No se puede calcular la distancia Manhattan")
  }
}
```

Como se necesita calcular la distancia entre cada posible par de puntos, se organizan estos datos en una matriz (representada por un dataframe) haciendo uso de la función anterior. Se tiene en cuenta que  $\text{dist}(x_i, x_j) = \text{dist}(x_j, x_i)$  y se recoge en la siguiente función.

```
create_distance_matrix = function(df) {
  empty_matrix = matrix(ncol = len(df[,1]), nrow = len(df[,1]))
  distances = data.frame(empty_matrix)
  for (i in 1:len(df[,1])) {
```

```

        p_dists = c()
        for (j in 1:len(df[,1])) {
            dist = manhattan_distance(df[i,], df[j,])
            distances[i,j] = dist
            distances[j,i] = dist
        }
        distances = rbind(distances, p_dists)
    }
    distances
}

```

Ahora se necesitará ordenar las distancias a los puntos para construir el conjunto  $N(x_i, k)$ . Para ello se hará uso del algoritmo de ordenación de la burbuja explicado en ejercicios anteriores, pero se le realizarán una serie de modificaciones para adaptarlo a este caso. Esto se realiza con la función que se presenta a continuación.

```

bubble_LOF = function(d_list, p_list) {
    n = len(d_list)
    for (i in 2:n) {
        for (j in 1:(n-1)) {
            if (d_list[j] > d_list[j+1]) {
                temp = d_list[j]
                d_list[j] = d_list[j+1]
                d_list[j+1] = temp

                temp = p_list[j]
                p_list[j] = p_list[j+1]
                p_list[j+1] = temp
            }
        }
    }
    data.frame("dis"=d_list, "poi"=p_list)
}

```

Esta función recibe los parámetros `d_list` y `p_list`, que representan las listas de las distancias y de los punto, respectivamente. En realidad, realiza lo mismo que el algoritmo visto en otros ejercicios, ordenando la lista `d_list`, pero aplica los cambios en las sucesivas iteraciones también en la lista `p_list`. Se devolverán dos columnas, una con listas de puntos, y otra con listas a las distancias a dichos puntos, ordenadas de forma ascendente. Estas listas serán paralelas (compartirán índices), y representarán al mismo elemento.

Una vez ordenadas las distancias y los puntos, deberán ser calculados los conjuntos  $N(x_i, k)$ . Por su propia definición se debe mirar (al menos) hasta el  $k$ -vecino

más cercano al punto, y añadir estos, y en caso de que los sucesivos  $k+\alpha$  compartan distancia con el  $k$ , entonces también deberán ser añadidos. Esto se recoge en la siguiente función:

```
get_n_set = function(df, k) {
  d_list = list()
  p_list = list()

  distance_matrix = create_distance_matrix(df)

  for (column in 1:len(distance_matrix[1,])) {
    ordered_column = tail(bubble_LOF(distance_matrix[,column],
                                     1:ncol(distance_matrix)), ncol(distance_matrix)-1)

    k_aux = k

    while(k_aux < nrow(ordered_column) &
          ordered_column[k_aux, "dis"] ==
          ordered_column[k_aux + 1, "dis"]) {
      k_aux = k_aux + 1
    }

    d_list = append(d_list, list(head(ordered_column[, "dis"], k_aux)))
    p_list = append(p_list, list(head(ordered_column[, "poi"], k_aux)))
  }
  data.frame(dis = I(d_list), poi = I(p_list))
}
```

En esta función se seleccionan los primeros  $k$ -vecinos. Obviamente, en primer lugar se eliminan los elementos  $\text{dist}(x_i, x_i)$ , pues siempre será igual a 0. Esto se logra con la función `tail` del paquete `utils` y que permite conservar el resto de distancias. Una vez seleccionados los  $k$  más cercanos, se va avanzando sobre el resto de vecinos y se revisa si el siguiente al último debe añadirse debido a que sean iguales, y así sucesivamente hasta encontrar una pareja de distancias diferentes, o no tener más vecinos. Se utiliza la función `head` del paquete `utils` para obtener el conjunto  $N(x_i, k)$  y se devuelven en un dataframe.

El siguiente paso es calcular la densidad de cada punto. Esta se realiza mediante la siguiente expresión:

$$\text{dens}(x_i, K) = \frac{|N(x_i, K)|}{\sum_{x_j \in N(x_i, K)} \text{dist}(x_i, x_j)}$$

En el código queda representado mediante la siguiente función. Basta con acceder a los datos correctos del dataframe devuelto por la función `get_n_set`. Esta función

devuelve una columna con las densidades de cada punto, la fila  $i$ -ésima almacena  $\text{dens}(x_i, k)$ .

```
add_list = function(l) {
  add = 0
  for (i in 1:len(l)) {
    add = add + l[i]
  }
  add
}
```

```
get_densities = function(n_set) {
  densities = c()
  for (i in 1:len(n_set[,1])) {
    densities = append(densities,
                      len(n_set[i,1][[1]]) / add_list(n_set[i,1][[1]]))
  }
  densities
}
```

Se hace uso de la función auxiliar `add_list`, que devuelve la suma de los elementos de una lista. En este caso  $\sum_{j=1}^{|N|} \text{dist}(x_i, x_j)$ .

A continuación, deberán calcularse las densidades relativas medias de cada punto, pudiendo identificar mediante estas los outliers. Esta se calcula mediante la siguiente expresión.

$$\text{drm}(x_i, K) = \frac{\text{dens}(x_i, K) \cdot |N(x_i, K)|}{\sum_{x_j \in N(x_i, K)} \text{dens}(x_j, K)}$$

En el código se calcula mediante la siguiente función, que representa la ecuación mostrada, pero adaptada a las estructuras de datos utilizadas durante el resto del algoritmo. Al igual que hacía `get_densities`, se devuelve una columna con los valores de  $\text{drm}(x_i, k)$ .

```
get_drm = function(n_set) {
  drms = c()
  for (i in 1:len(n_set[,1])) {
    add_densities = 0

    points = n_set[i, "poi"][[1]]
    for (j in 1:len(points)) {
      add_densities = add_densities +
```

```

                                n_set[points[j], "densities"]
                                }

                                drm = n_set[i, "densities"] * len(points) / add_densities
                                drms = append(drms, drm)
                                }
                                drms
                                }

```

Finalmente, se unen todos los pasos comentados en la función `lof`. Esta muestra un dataframe con los parámetros que se han ido calculando. Para ello se emplea la función `cbind` para ir construyendo dicho dataframe.

```

lof = function(muestra, k) {
  n_set = get_n_set(muestra, k)

  densities = get_densities(n_set)
  n_set = cbind(n_set, densities)

  drms = get_drm(n_set)

  n_set = cbind(n_set, drms)
  n_set
}

```

Se comprueban los resultados obtenidos, dejando a juicio del analista el valor de  $k$  y la selección de outlier en función de la `drm`.

```

muestra = data.frame("mujeres" = c(9,9,11,2,11), "hombres" = c(9,7,11,1,9))
(lof(muestra, 3))

```

```

##           dis      poi densities      drms
## 1      2, 2, 4 2, 5, 3 0.37500000 1.285714
## 2      2, 4, 6 1, 5, 3 0.25000000 0.750000
## 3      2, 4, 6 5, 1, 2 0.25000000 0.750000
## 4 13, 15, 17 2, 1, 5 0.06666667 0.200000
## 5      2, 2, 4 1, 3, 2 0.37500000 1.285714

```